

Redes Neurais Convolucionais

André Gustavo Hochuli

Orientador: Prof. Dr. Luiz Eduardo Soares de Oliveira

Programa de Pós-Graduação em Informática

Departamento de Informática

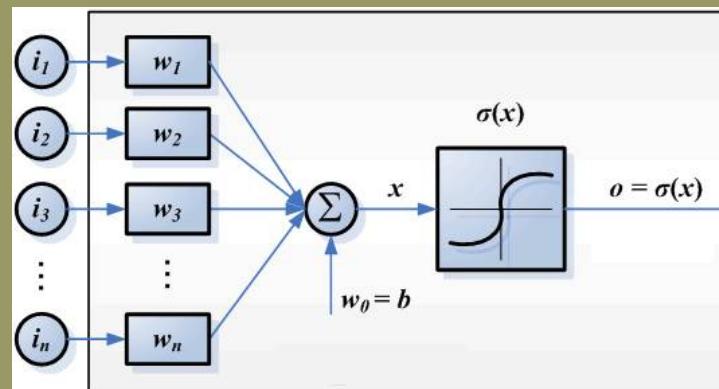
UFPR

<http://www.inf.ufpr.br/aghochuli/caffe/>

Redes Neurais

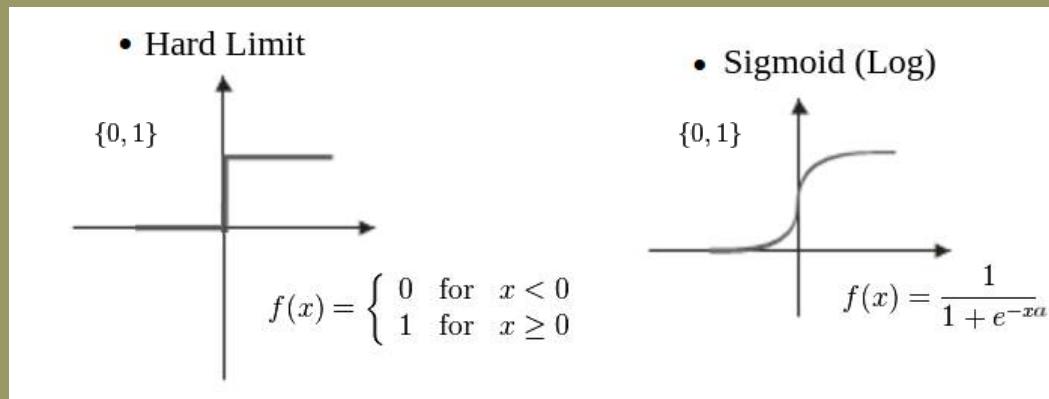
- Neurônio Artificial

- Vetor de Características
- Pesos
- Bias
- Função de Ativação



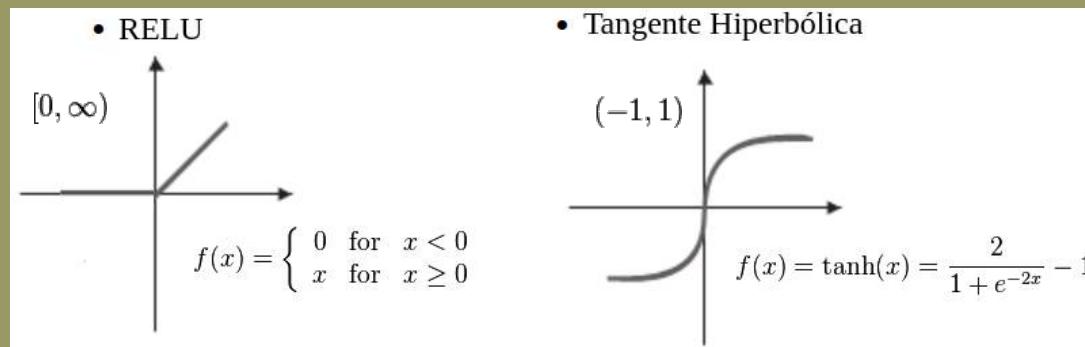
- Funções de Ativação

- Dado uma entrada, define um estado para o neurônio.

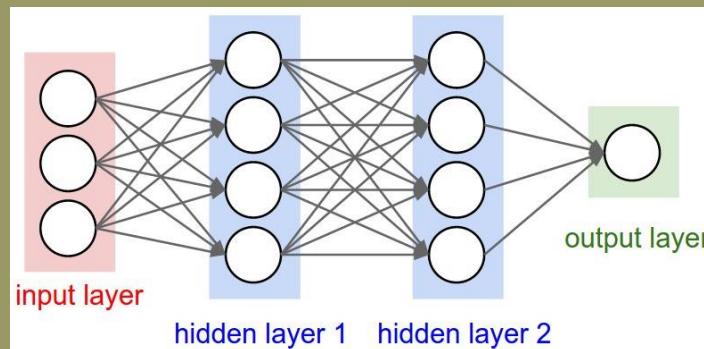


Redes Neurais

- Funções de Ativação

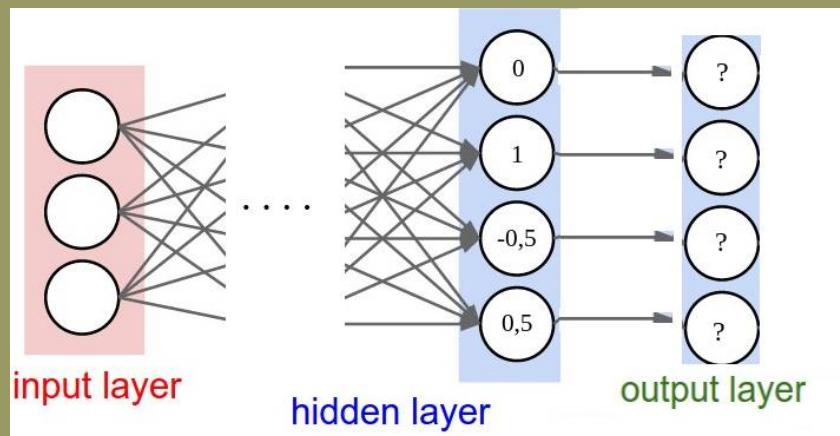


- Rede Neural Artificial (MLP)



Redes Neurais

- Problema: Como determinar a probabilidade de cada classe na camada de saída da rede neural ?

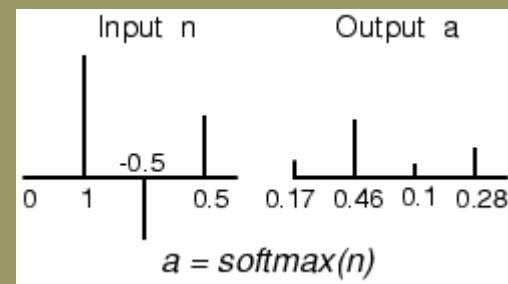


Redes Neurais

- Função SoftMax

- Normaliza entre 0 e 1 as saídas, em um problema multi-classes, obtidas por um classificador linear (Ex: Neurônios).
- Aplicada na camada de saída da rede (output layer).
- Objetivo: Definir a probabilidade de uma classe dentro de um problema multi-classes

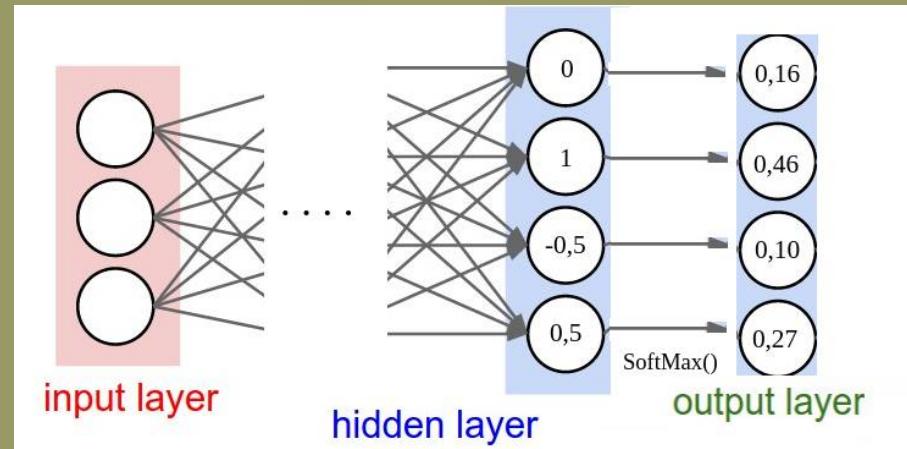
$$y_i = \frac{e^{z_i}}{\sum_{j \in group} e^{z_j}}$$



Redes Neurais

- Função SoftMax - Exemplo

$$y_i = \frac{e^{z_i}}{\sum_{j \in group} e^{z_j}}$$



$$e^0 = 1.0000$$

$$e^1 = 2.7182$$

$$e^{-0.5} = 0.6065$$

$$e^{0.5} = 1.6487$$

$$\sum_{j \in group} e^{z_j} = \sim 5.9734$$

$$y_0 = \frac{1.0000}{\sim 5.9734} = 0.16$$

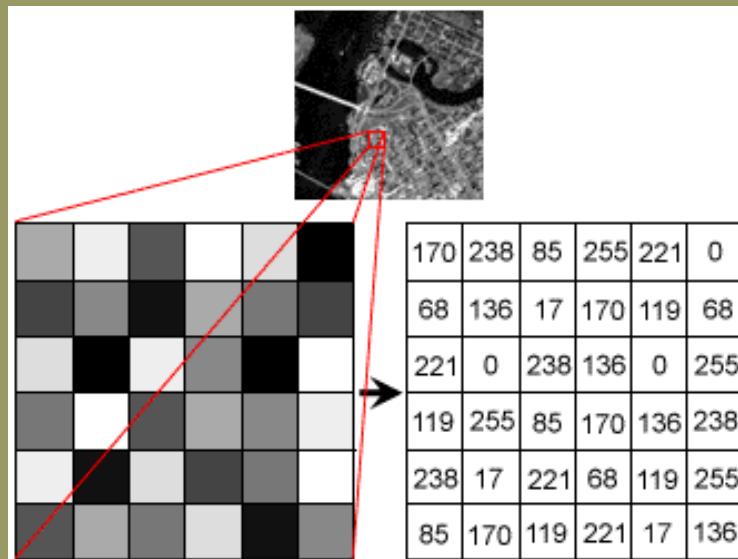
$$y_1 = \frac{2.7182}{\sim 5.9734} = 0.46$$

$$y_2 = \frac{0.6065}{\sim 5.9734} = 0.10$$

$$y_3 = \frac{1.6487}{\sim 5.9734} = 0.27$$

Imagen Digital

- Representação

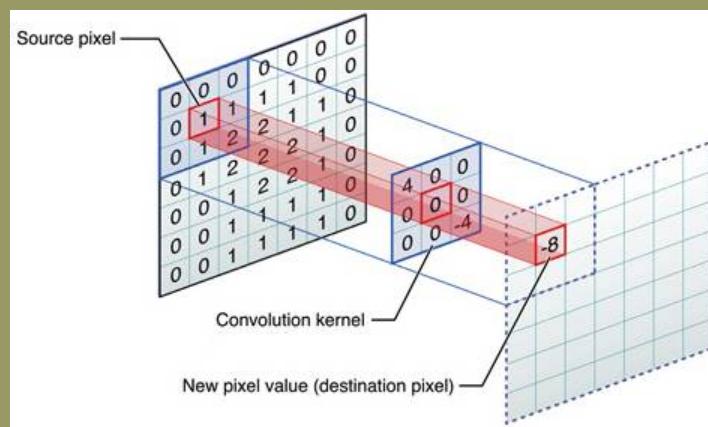


- Escala de Intensidade

Imagen	Variação
8 Bit (Nível de Cinza)	$2^8 (0 - 255)$
24 Bit (Colorida 3 Canais)	$2^{24} (0 - 16777215)$

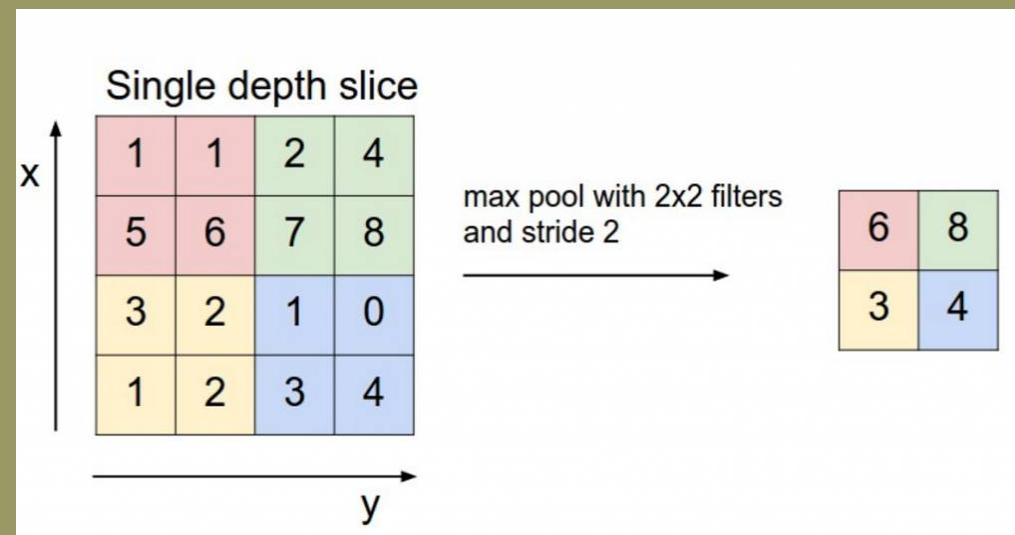
Convoluçãoes

- Operações entre Matrizes (Imagen X Kernel)
Ex: Filtros, Bordas, Etc
- Parâmetros do Kernel
 - Tamanho
 - Passo / Salto
 - Pesos
 - “Padding”



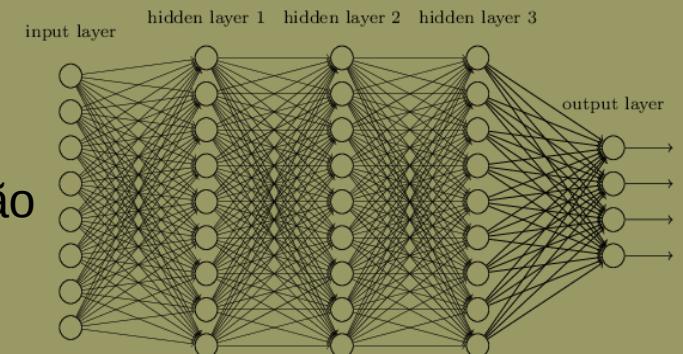
Pooling (Agregação)

- Convolução para reduzir escala (downsampling)
- Max, Avg, Mediana, etc.
- Max é o mais comum

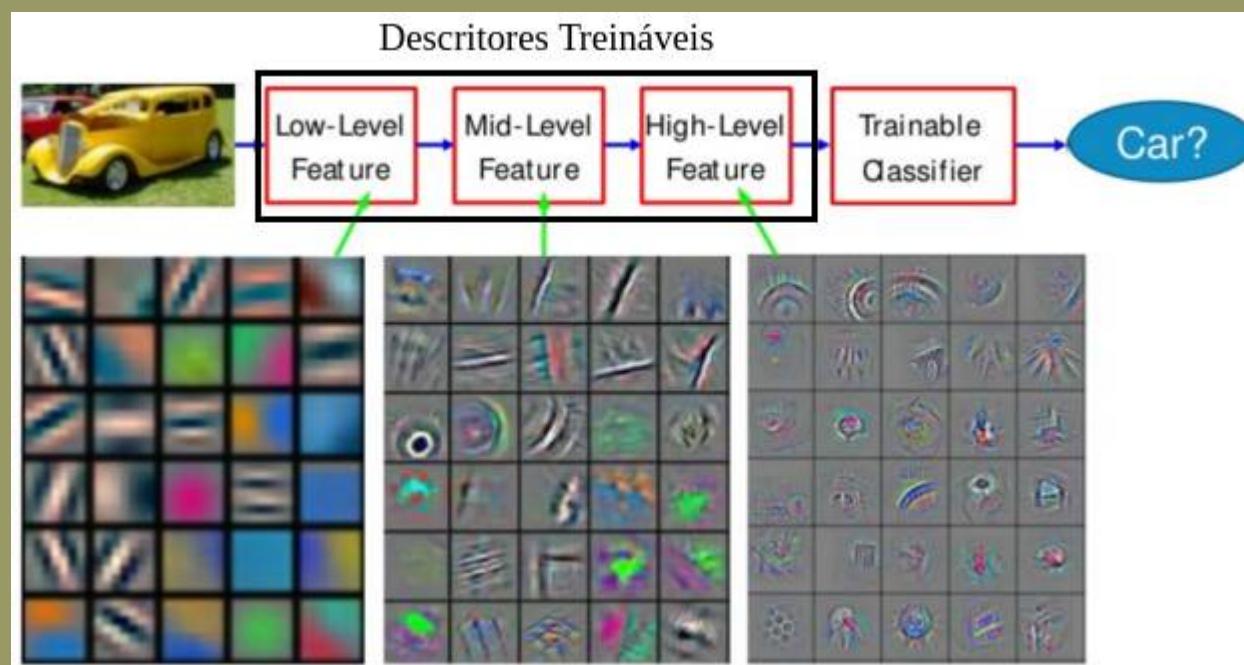
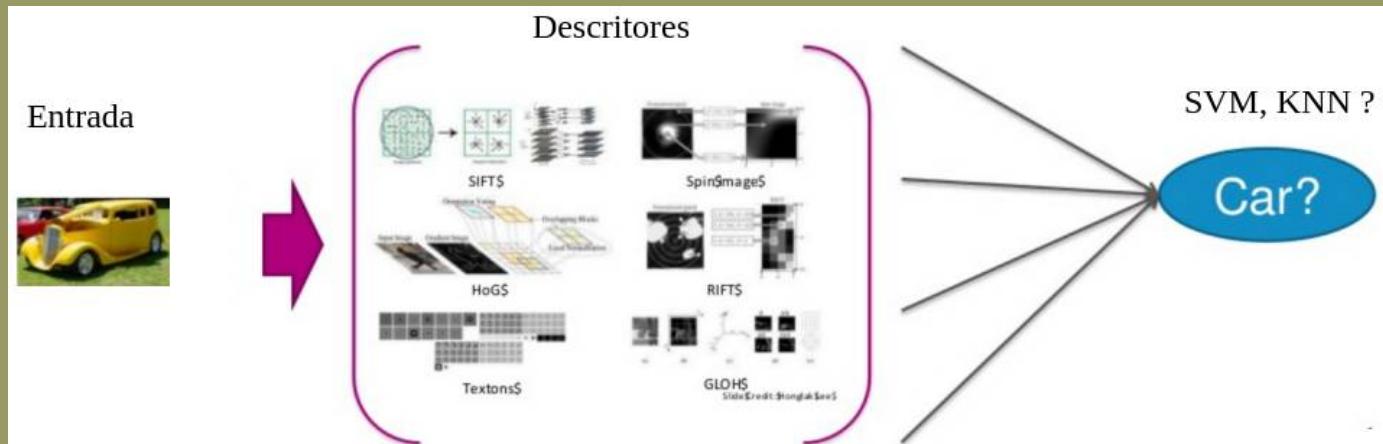


Deep Learning

- Aprendizado baseado em Multi-Camadas (RN Densas)
- Representação dos dados em diferentes níveis de abstração
- Extração de Características é Implícita
- Elevada quantidade de parâmetros (Ajuste por BackPropagation)
- Necessita de um grande número de exemplos para o aprendizado eficiente
- O aprendizado é voltado para compreensão pela máquina, ou seja, os dados são de difícil compreensão/visualização humana
- Vasta aplicação na área de Visão Computacional (processamento de áudio, imagens, vídeo, etc).



Feature Extraction X Deep Learning

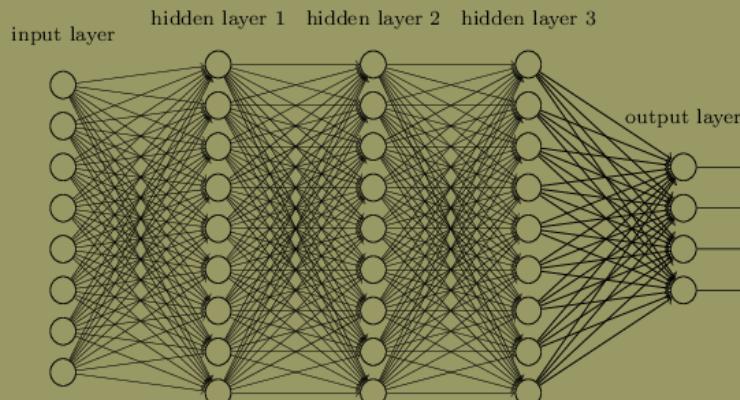


Redes Neurais Convolucionais

Deep Learning – Vanish Gradient Problem

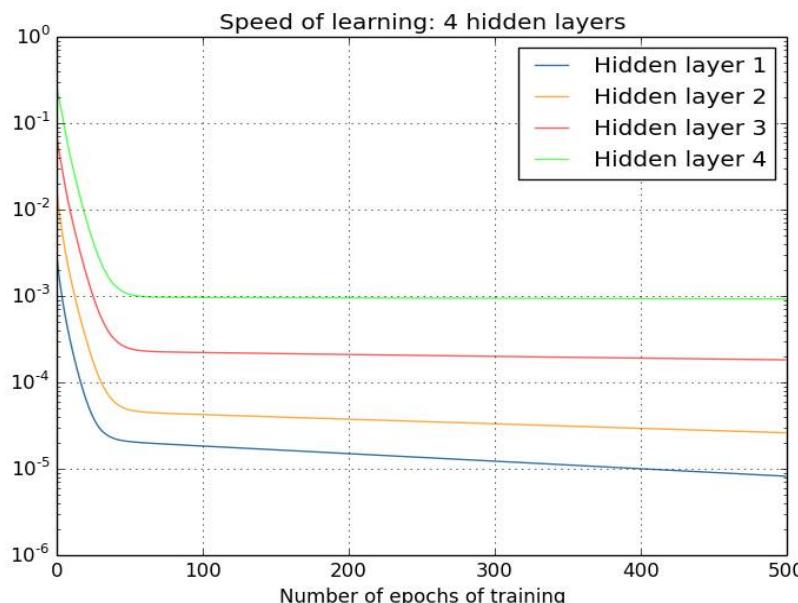
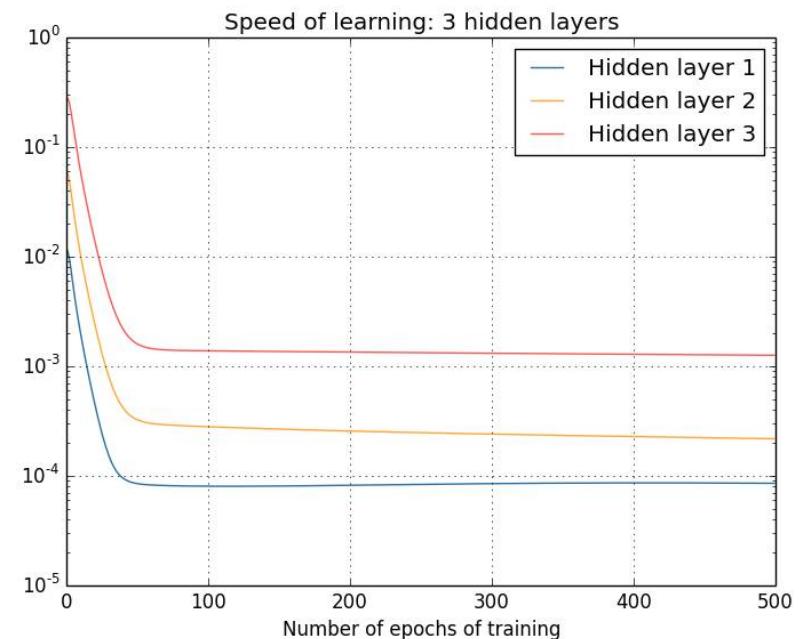
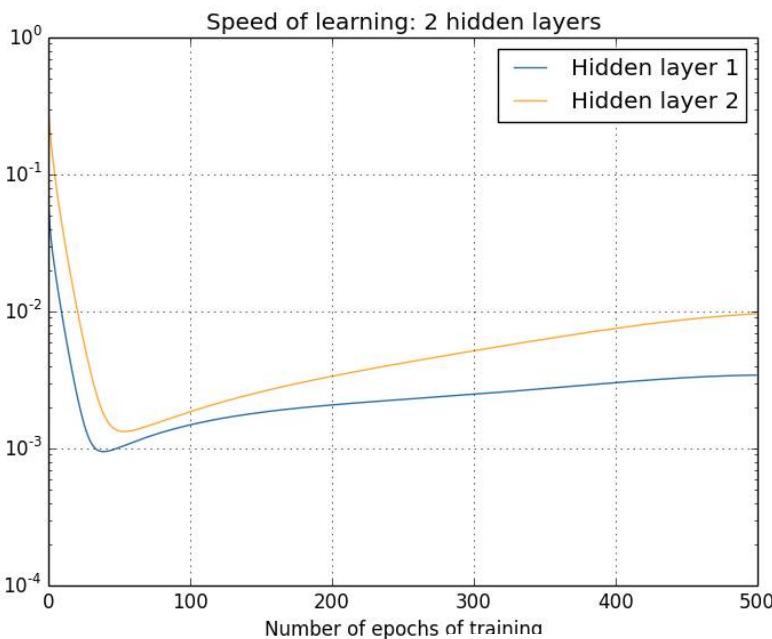
Problema do desaparecimento do gradiente e convergência da rede

- Valores de entrada mapeados em gradientes pequenos
 - Ativação por Sigmoid [$0 \rightarrow 1$] ou Tangh [$-1 \rightarrow 1$]
 - Variação “pequena”
-
- Agrava ao longo de uma rede múltiplas camadas
 - Uma mudança de valores na entrada, pouco altera as camadas mais distantes



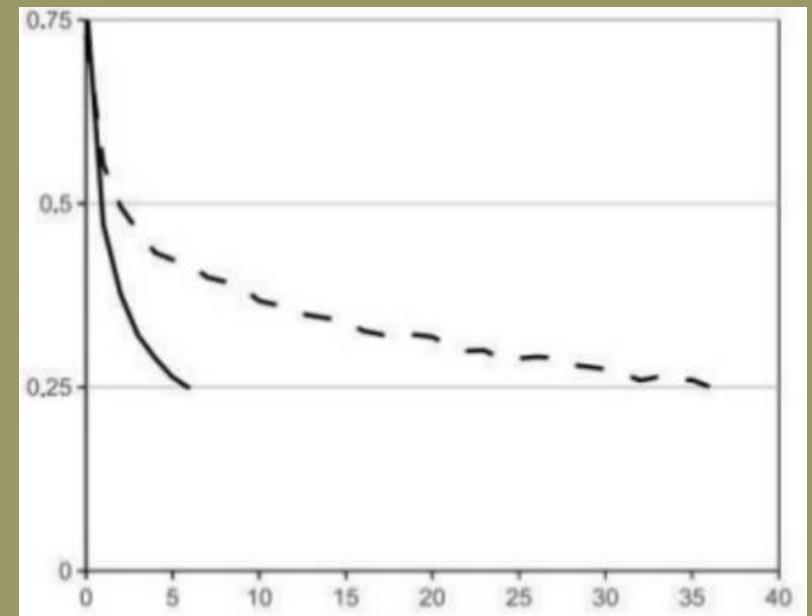
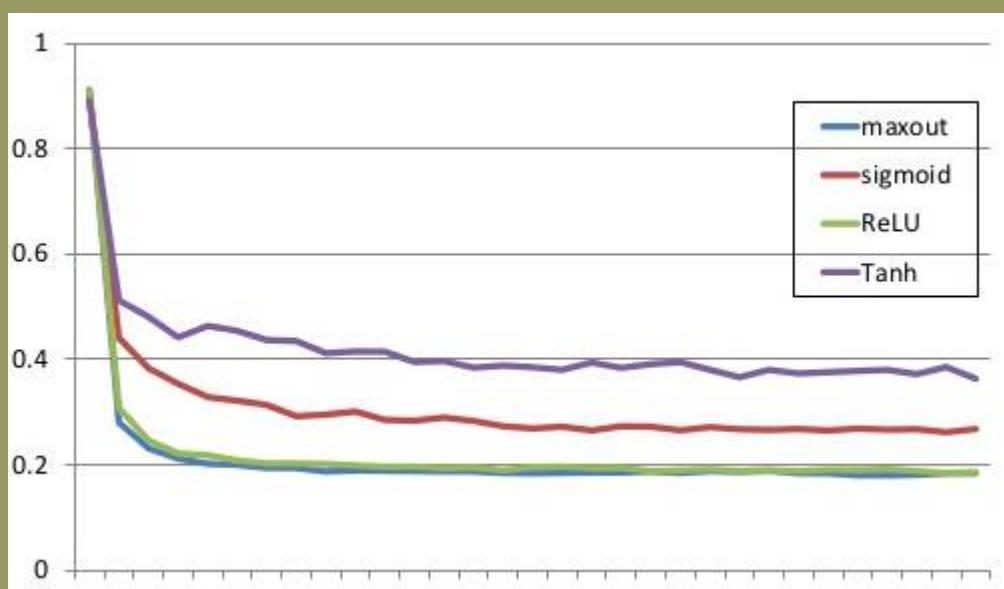
- Aprendizado mais se torna mais lento
- Solução encontrada: RELU [$f(x) = \max(0,x)$]
 - Mapeamento $[0,\infty]$

Deep Learning – Vanish Gradient Problem



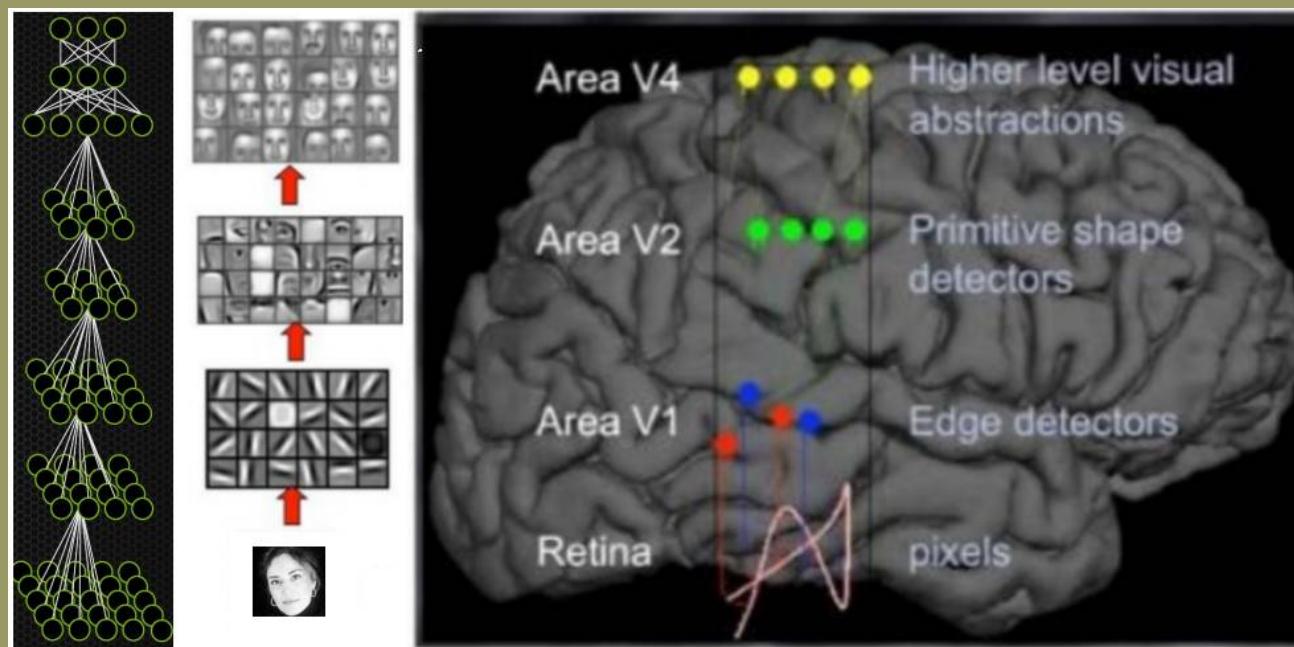
Deep Learning – Vanish Gradient Problem

- Sigmoid/Tanh $[-1, 1]$ = Aprendizado Lento / Custo computacional mais alto (expoentes e multiplicações)
- RELU $[0, \infty]$ = Aprendizado Rápido / Custo computacional mais baixo (threshold)



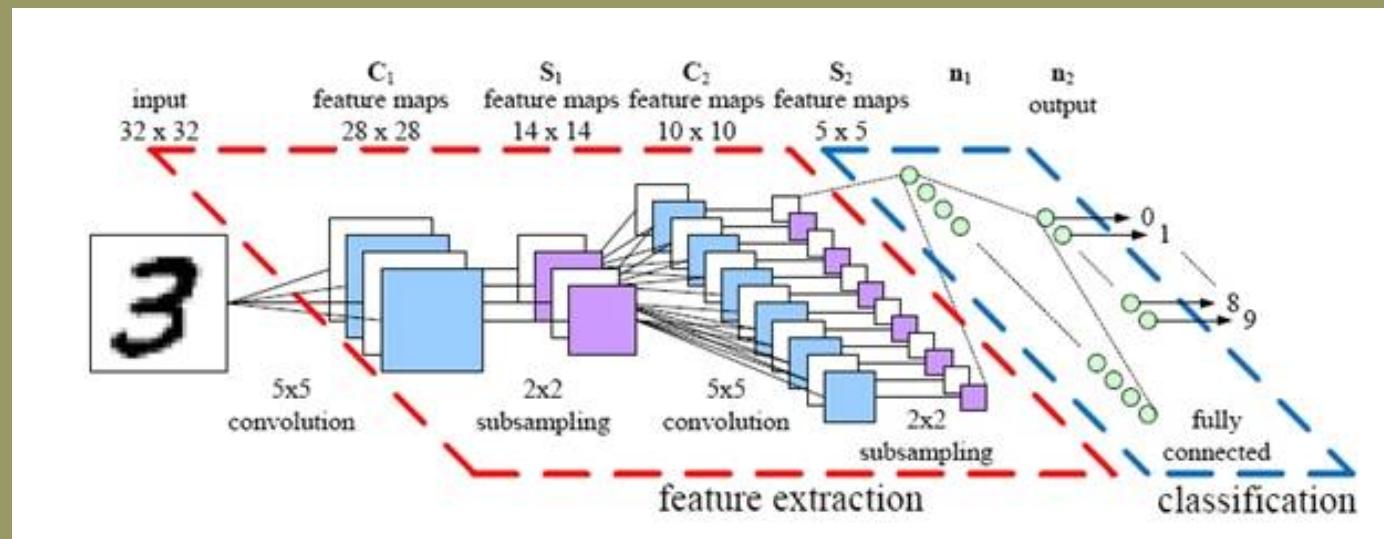
Redes Neurais Convolucionais

- Inspiradas no modelo biológico da visão
- Conceito de Deep Learning (Multi-Camadas)
- Idealizada no ínicio do anos 90 [Lecun], e vasta aplicação após 2006 devido a “popularização” de GPU's (Custo ~\$ 3000,00)
- Treinamento requer alto custo computacional e numerosa base de dados



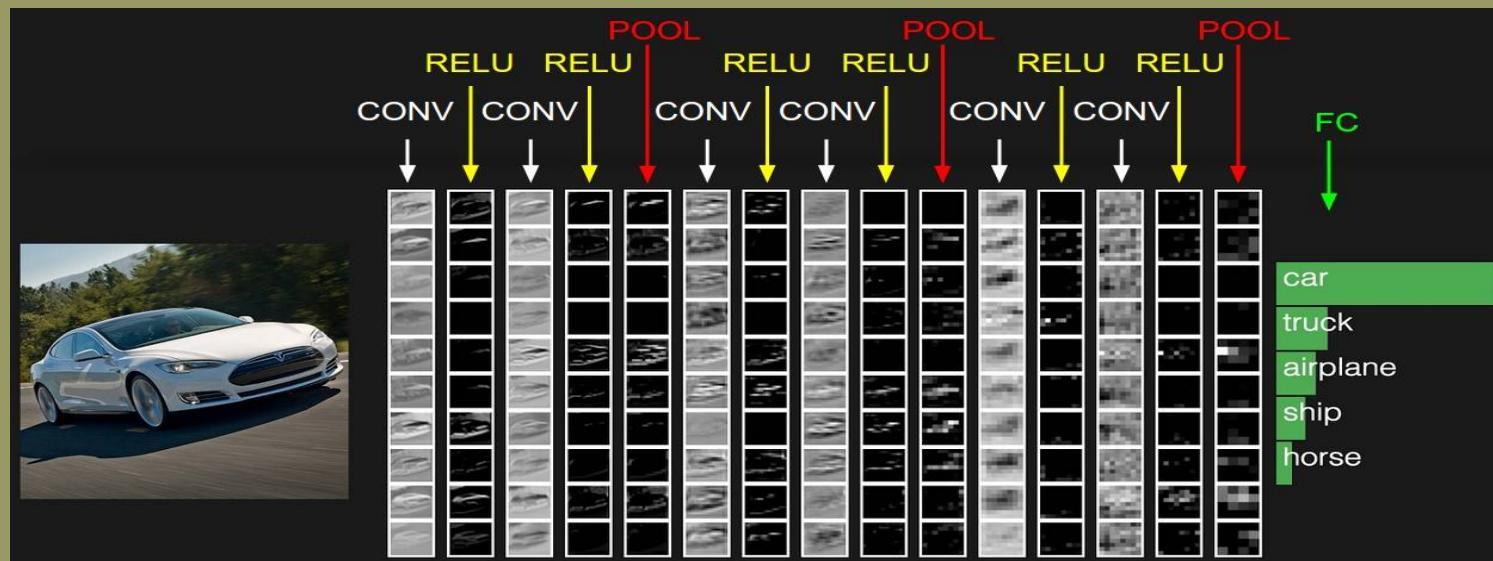
Redes Neurais Convolucionais

- Compostas de duas grandes etapas:
 - Extração de Características pelas Camadas Convolucionais
 - Classificação



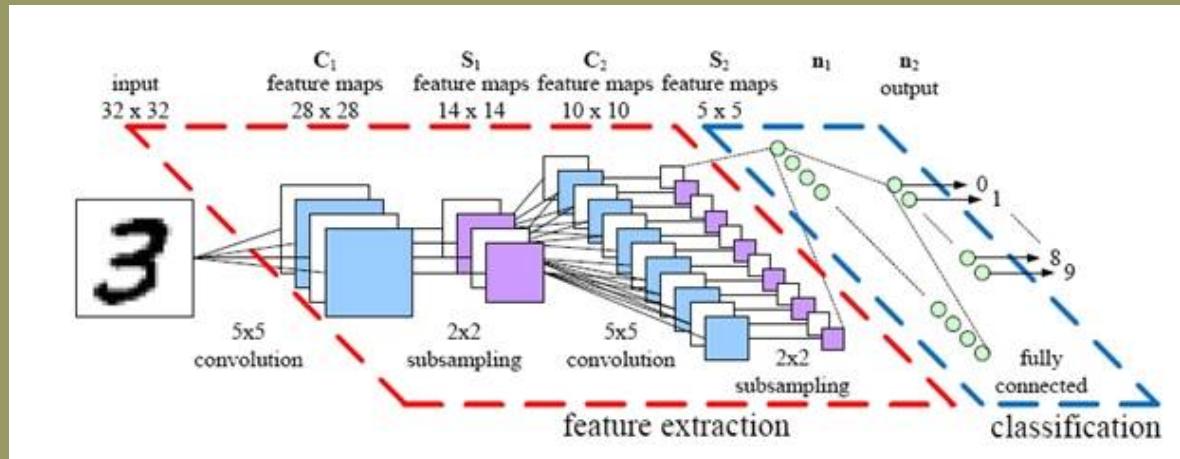
Tipos de Camadas (Layers)

- Convolucional : Definem os filtros (Aprendizado / BackPropagation)
- Ativação: Neurônios (Relu / Sigmoid / TangH)
- Pooling : Reduzem as escalas (Max, Median, etc..)
- Fully-Connected (FC): Camada que determina as classes (Classificador)



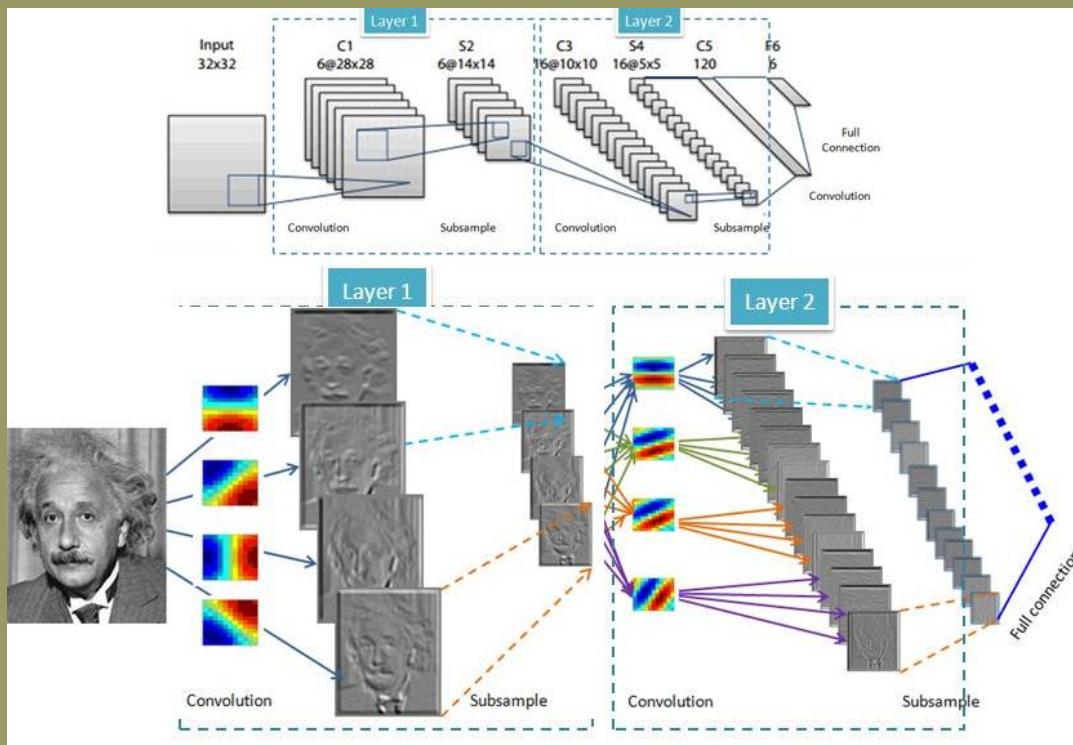
Extração de Características

- Transforma uma imagem em um vetor de características
 - Sequência de Convoluçãoes, Ativação e Pooling's
 - Convoluçãoes: altera a representação dos dados e aprende os filtros
 - Pooling: reduz a escala para o próximo layer
- Como ?
- Pesos dos filtros são calculados automaticamente (BackPropagation)
- Cada filtro aprendido é um extrator de características
- Cada imagem resultante de um filtro é um mapa de características
- Os pooling's são necessários para reduzir a quantidade de características por filtro (redução de escala)

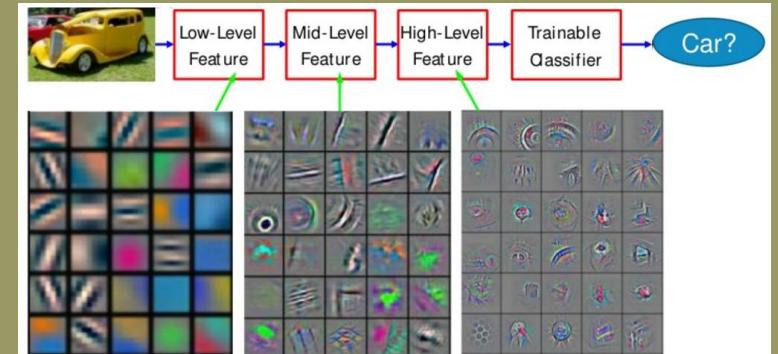


Extração de Características

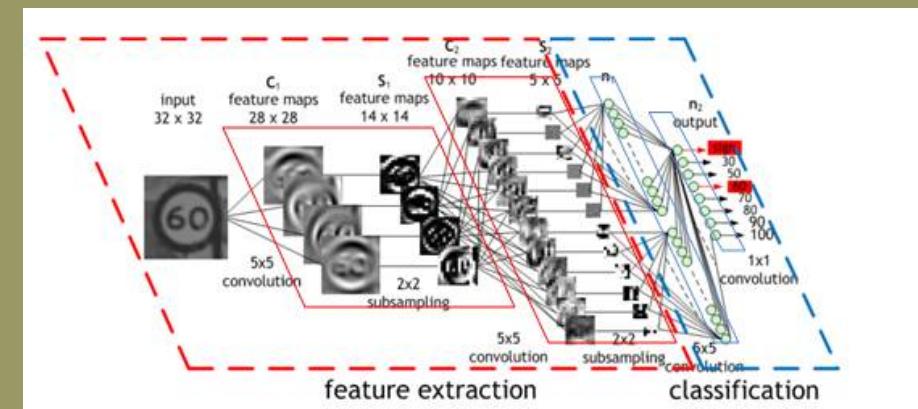
- Exemplos:



→ Filtros + Conv + Pool



→ Filtros Treinados (Aprendidos)



→ Representação dos dados

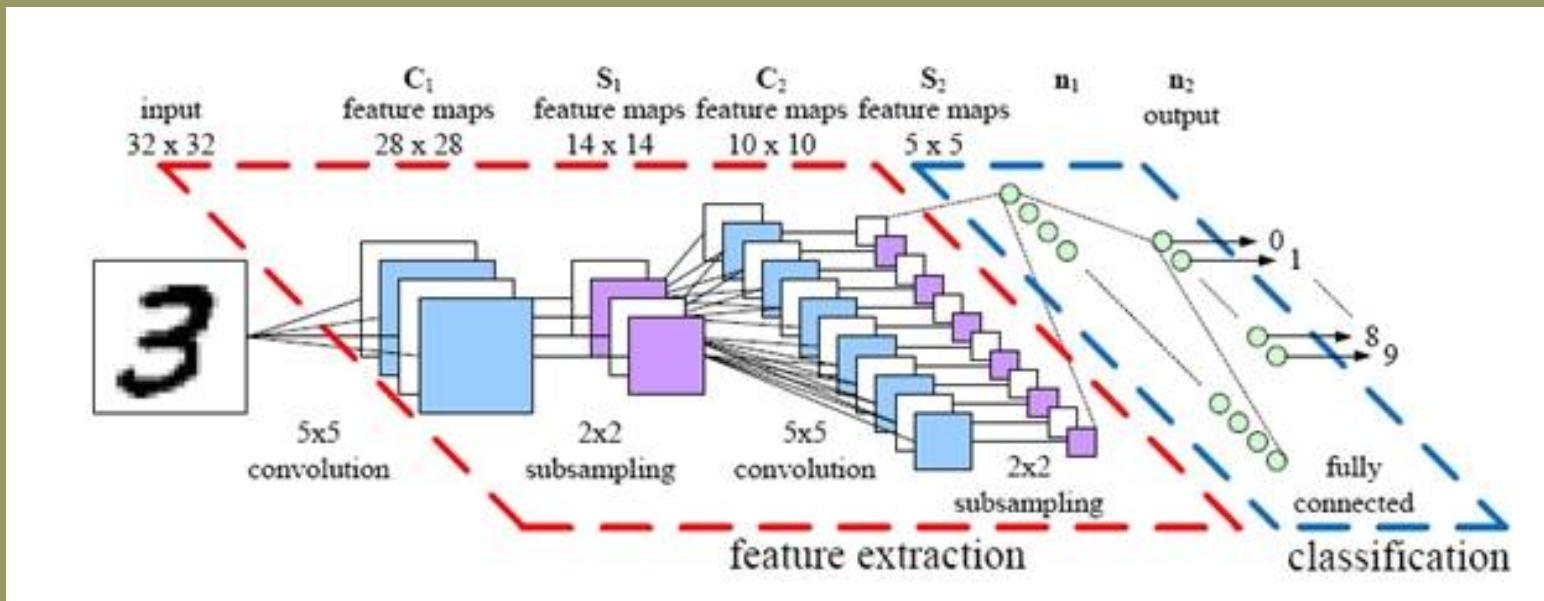
Extração de Características

- Exemplos:



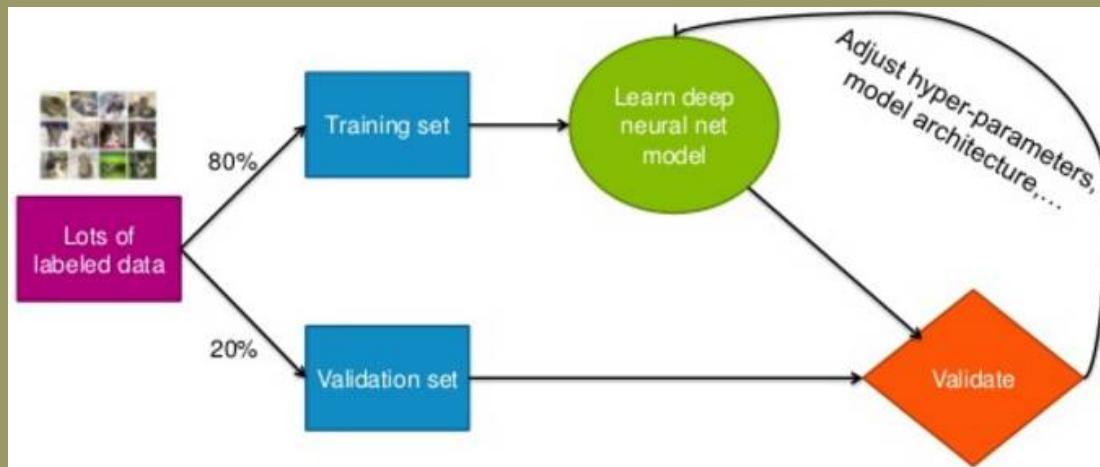
Extração de Características

- Números de neurônios por convolução



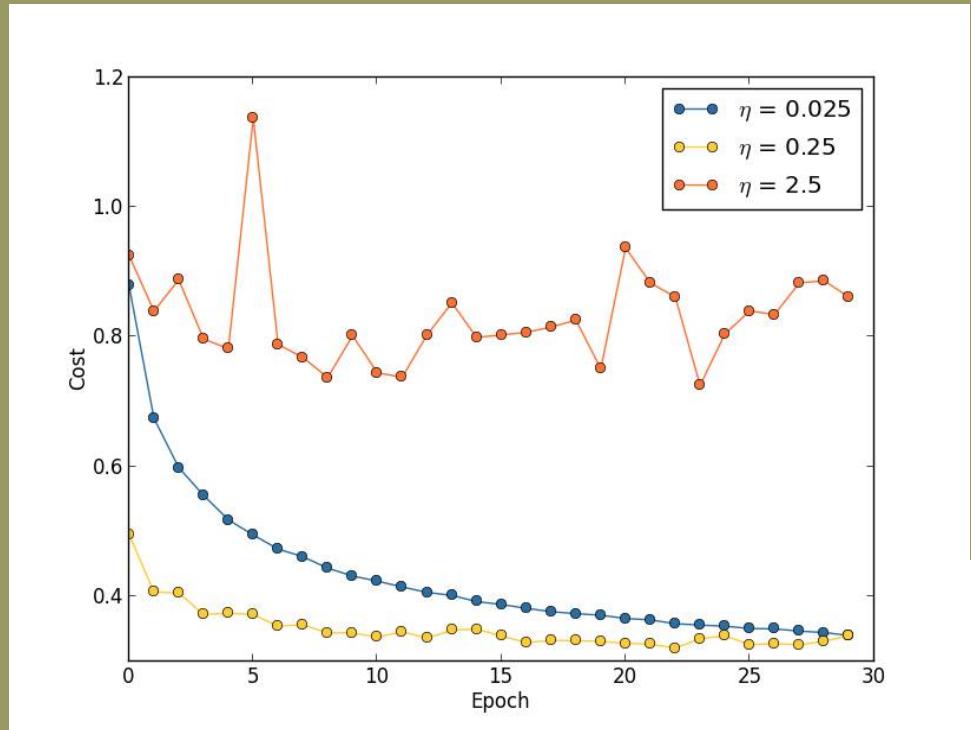
- C1: 3136 ($28 \times 28 \times 4$)
- S1: 1568 ($C1 / 2$)
- C2: 1200 ($10 \times 10 \times 12$)
- S2: 600 ($C2 / 2$)

Treinamento X Teste



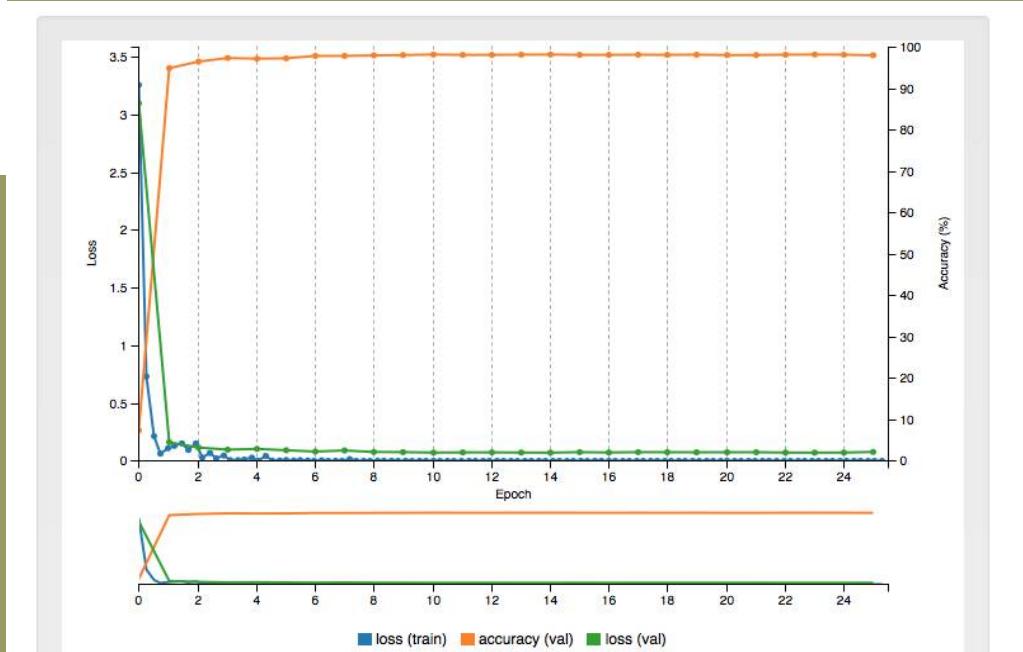
- Treinamento
 - Inicialização dos filtros e FC (Random – Const – Gaussian – Xavier)
 - Fase de Aprendizado (Pode demorar horas ou dias dependendo da configuração da rede)
 - Validação e Backpropagation
 - Armazenamento dos pesos e filtros ao longo do processo
- Teste da CNN
 - Utiliza os filtros e pesos da época definida

Treinamento



Rede “IDEAL”
Aprendizado em poucas épocas

Desempenho do Aprendizado
para diferentes “Learning
Rates”



Data Augmentation

- O que fazer se houver poucos exemplos na base ? Ou pouca variabilidade de uma mesma classe ?

Amostra →



Data Augmentation →



Ampliação do número de amostras
modificando a amostra original:

- Translações
- Ruídos
- Brilho / Contraste
- Flip's
- Smooth's

Redes Neurais Convolucionais

Deep Learning / CNN - Análise

Pros

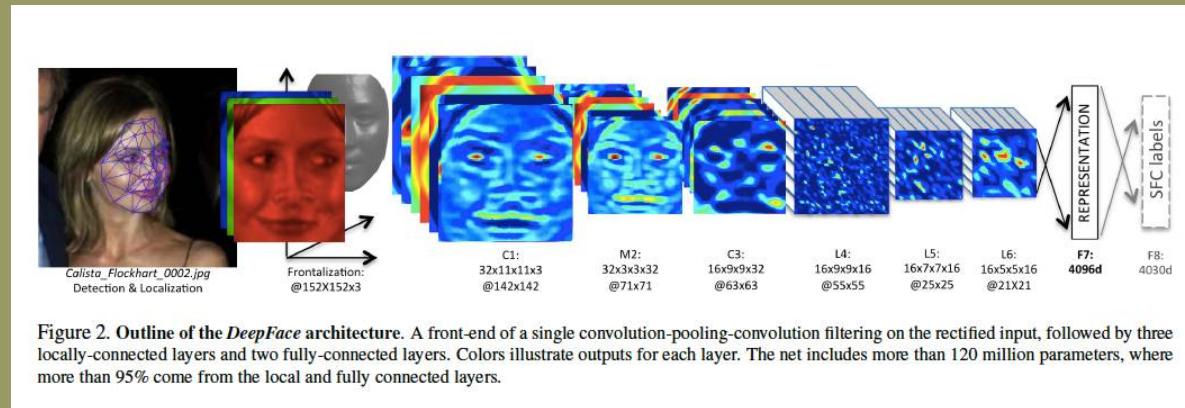
- Enables learning of features rather than hand tuning
- Impressive performance gains on
 - Computer vision
 - Speech recognition
 - Some text analysis
- Potential for much more impact

Cons

- Computationally really expensive
- Requires a lot of data for high accuracy
- Extremely hard to tune
 - Choice of architecture
 - Parameter types
 - Hyperparameters
 - Learning algorithm
 - ...
- Computational + so many choices = incredibly hard to tune

Algumas Aplicações

- Faces

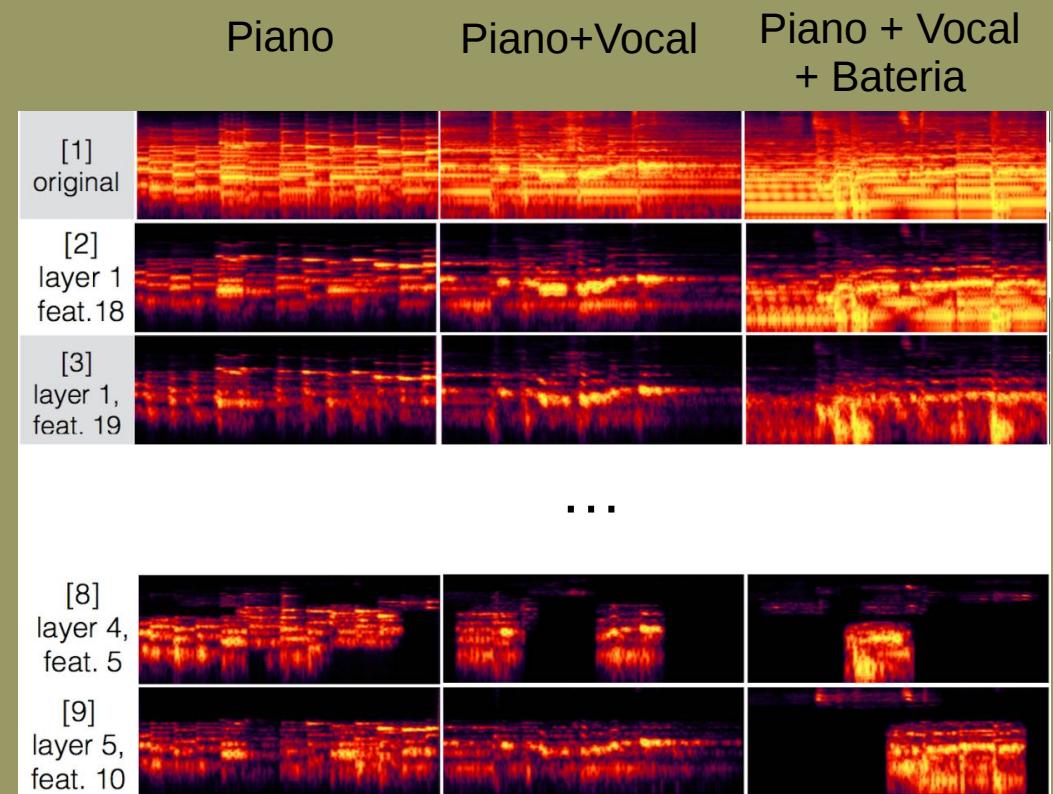
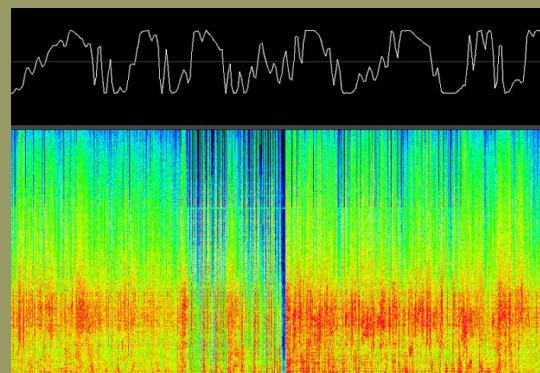


- PKLot



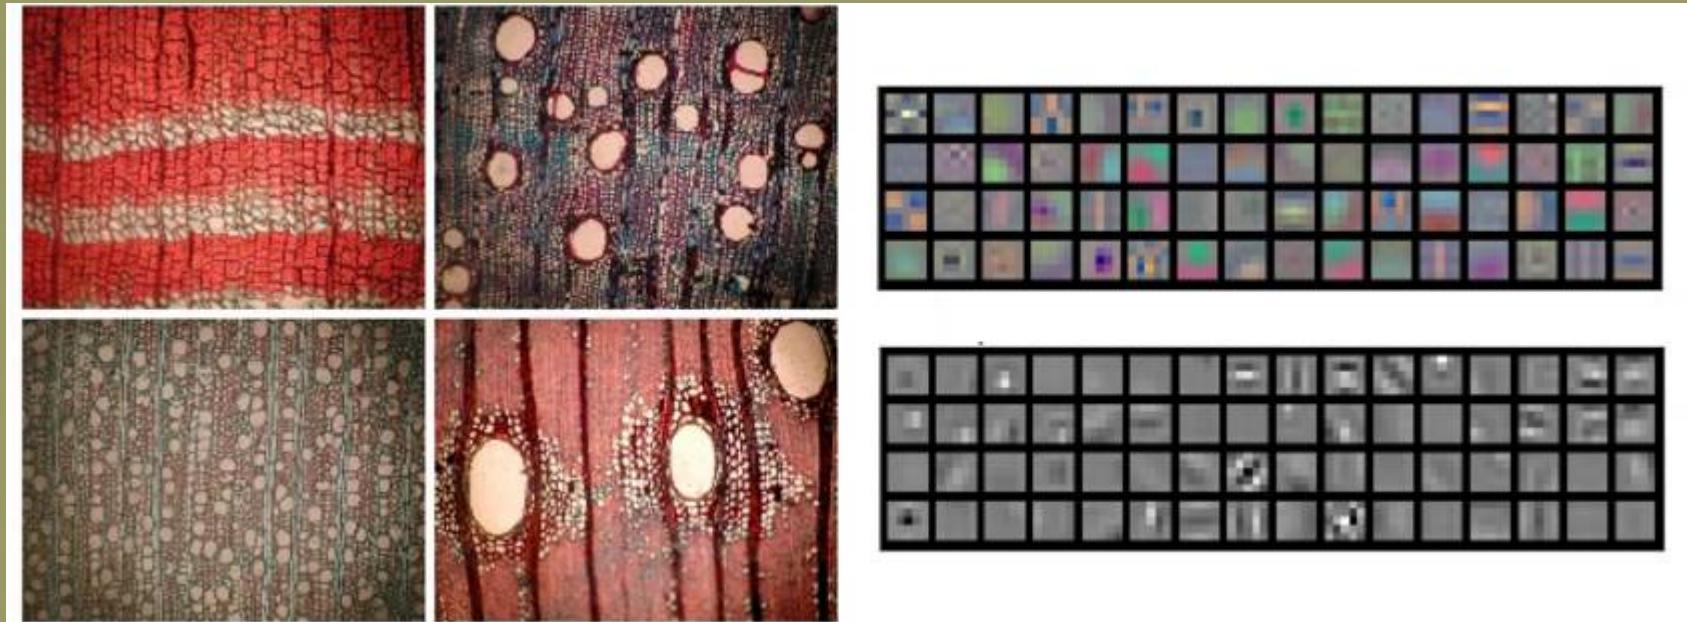
Algumas Aplicações

- Processamento de Áudio (Vocal / Genêro Musical)



Algumas Aplicações

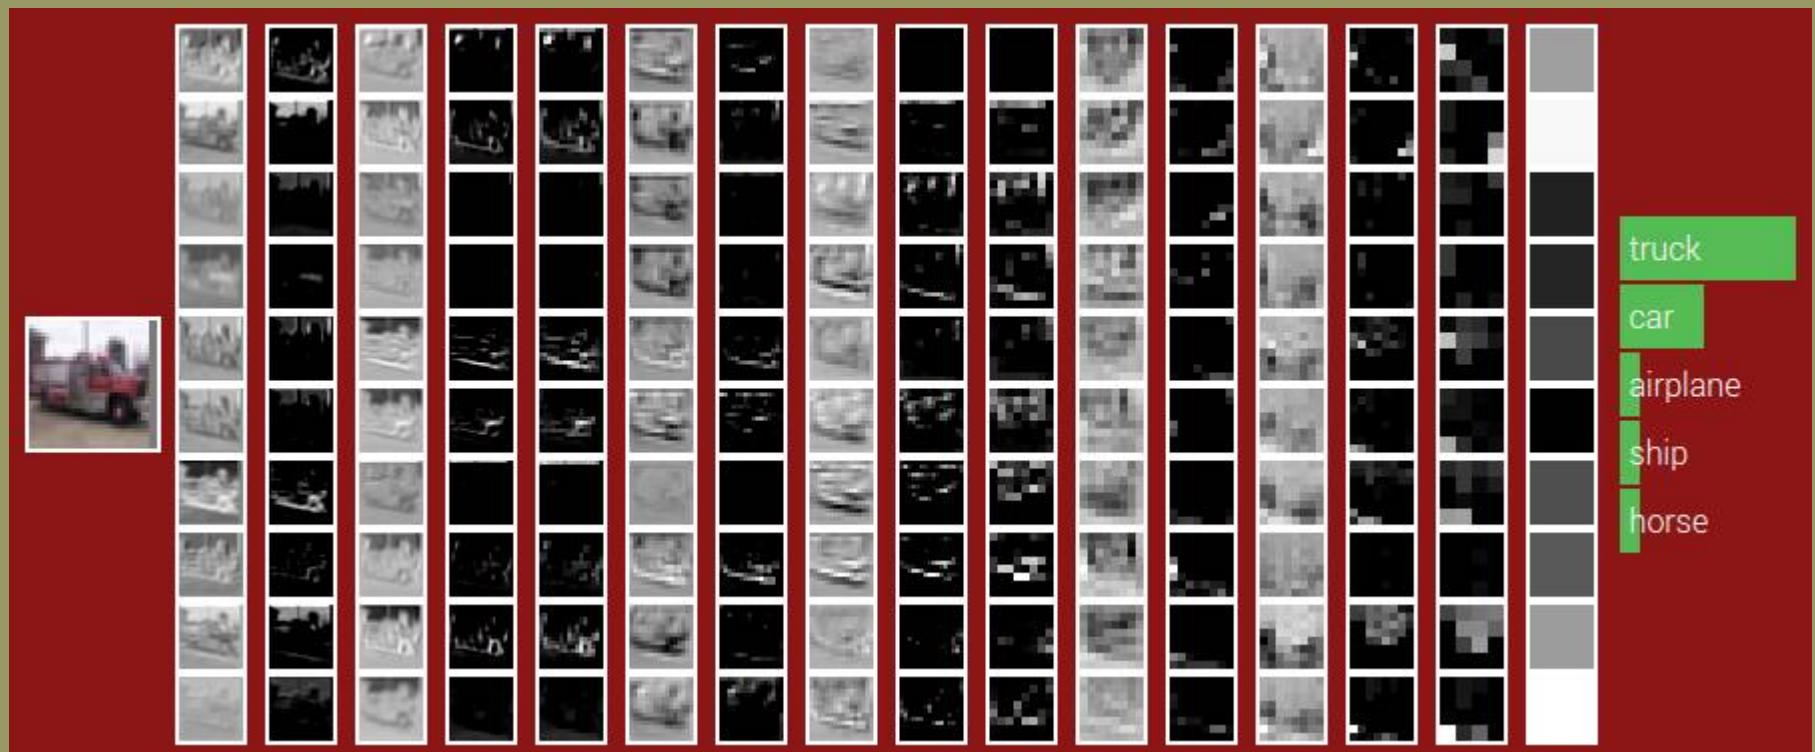
- Texturas
 - Tecido Celular
 - Células Cancerígenas
 - Espécie Florestal



Redes Neurais Convolucionais

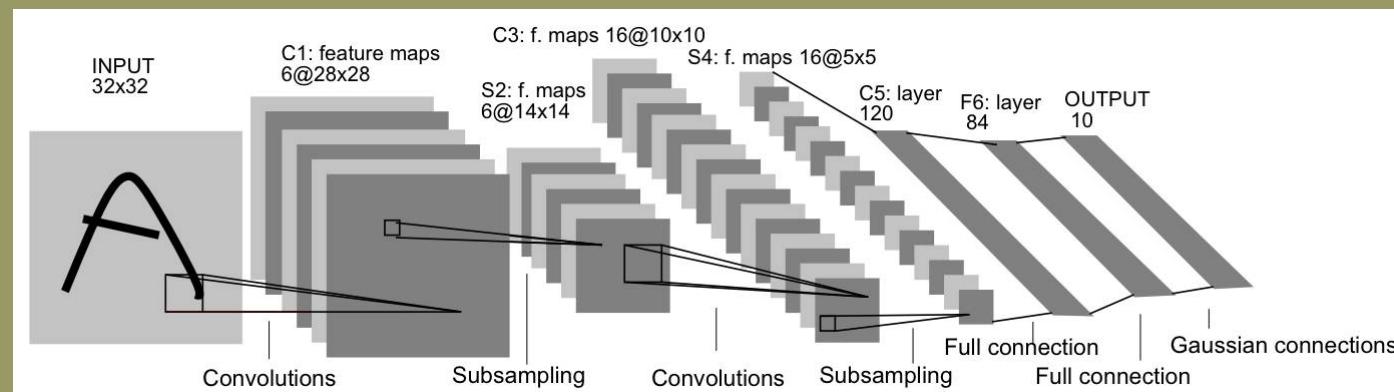
Algumas Aplicações

- Contexto de Imagens

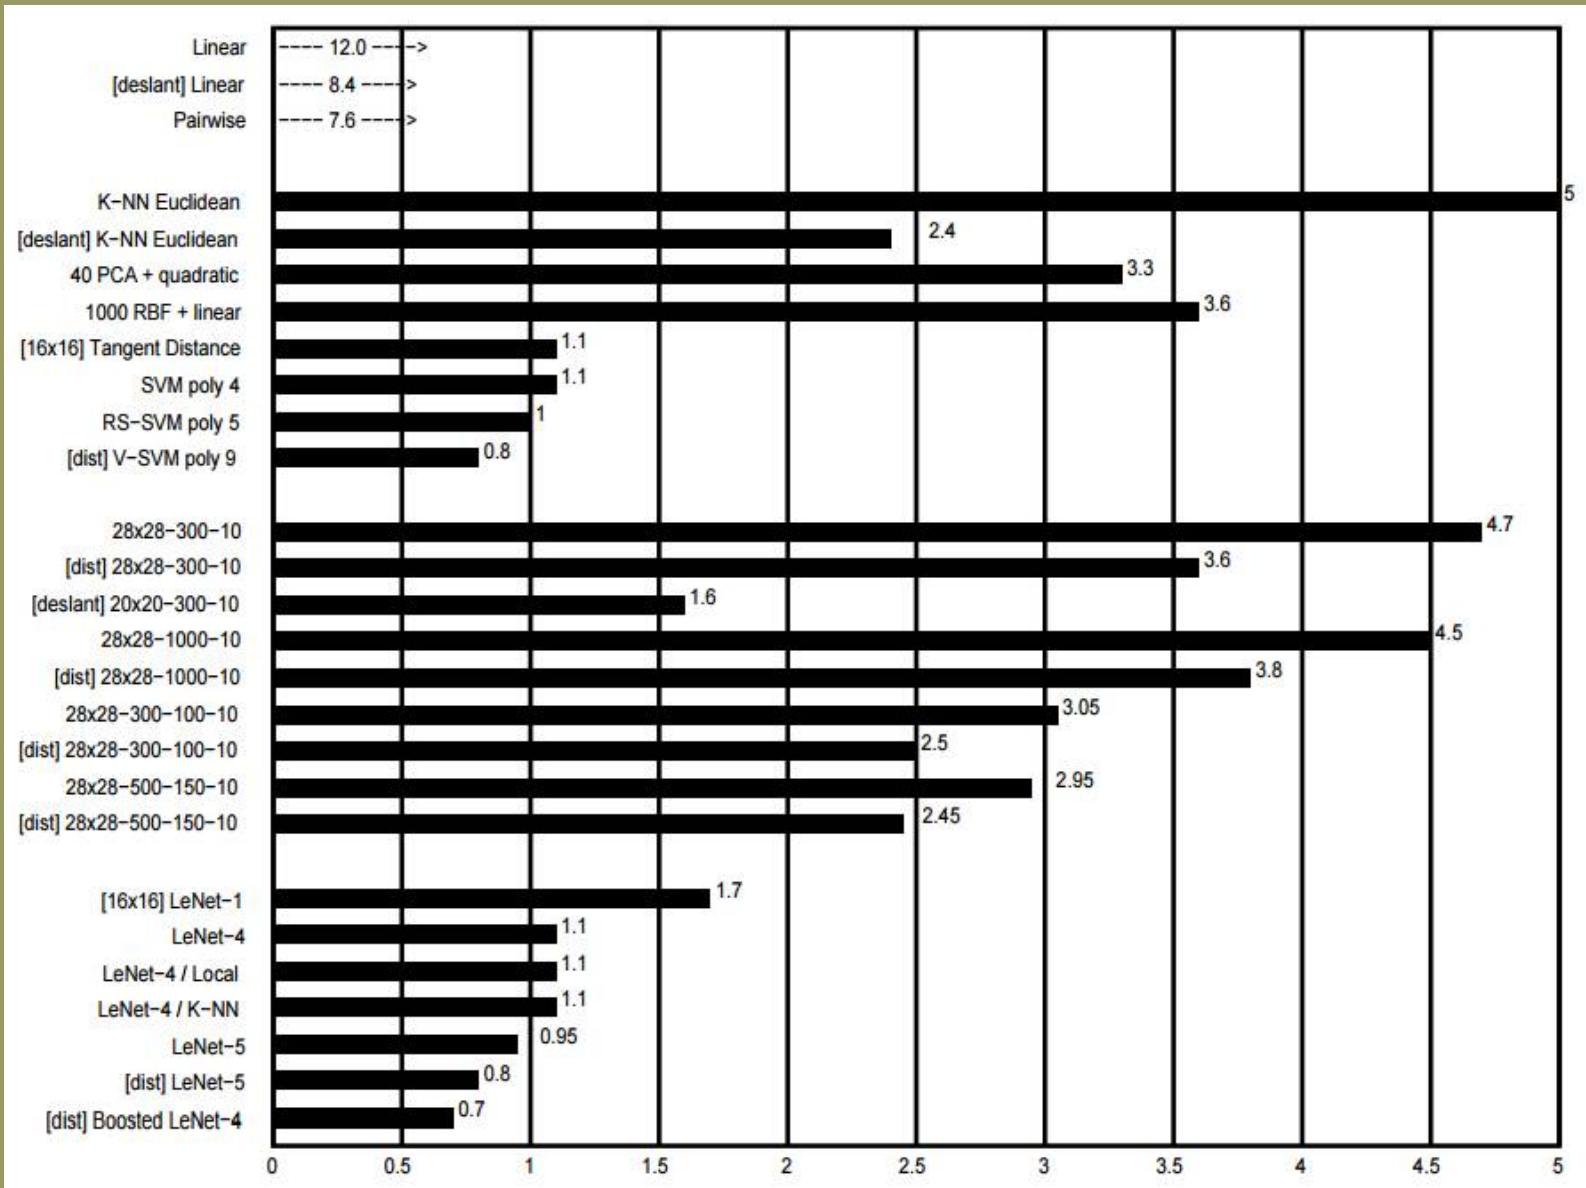


LENET-5

- Yan Lecun – 1998
- Primeira CNN implementada e testada com sucesso (Bell Labs)
- Reconhecimento de Dígitos Manuscritos
 - MNIST DATASET (10 Classes [#0....#9])
 - 60 K Treinamento
 - 10 K Teste
- 0.95% (erro)
- ~ 345 K de conexões
- ~ 60 K parâmetros

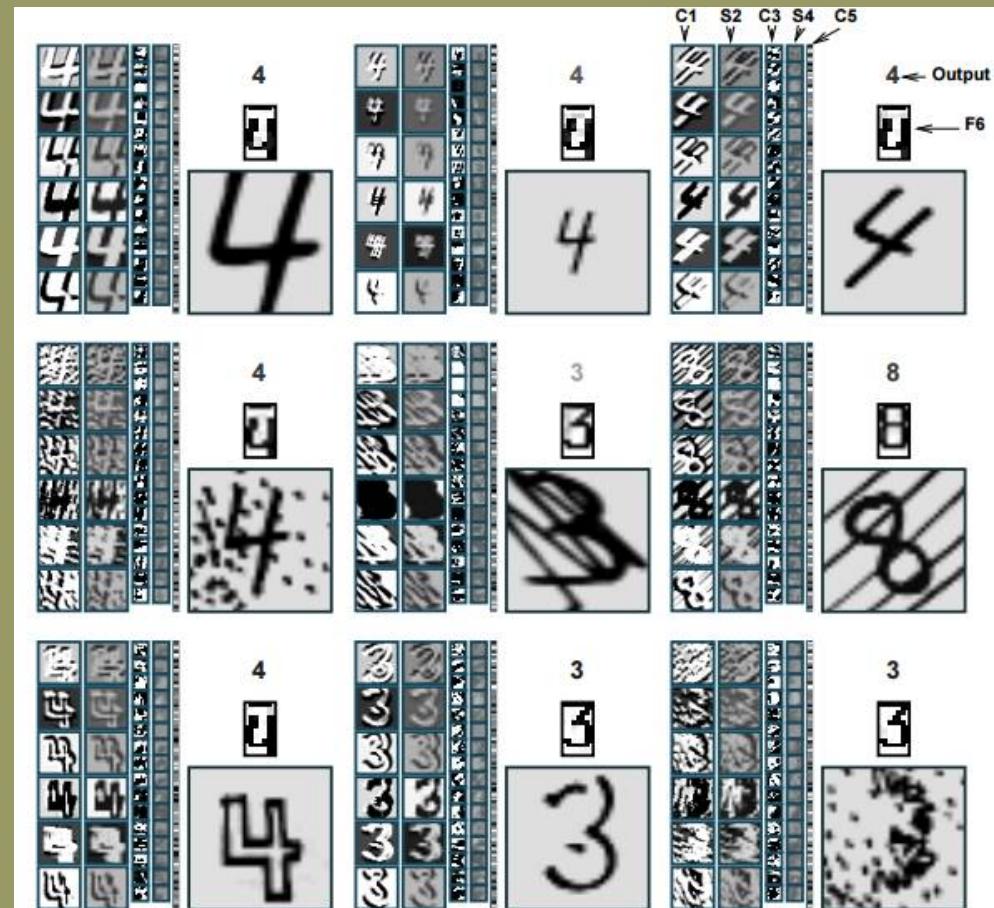
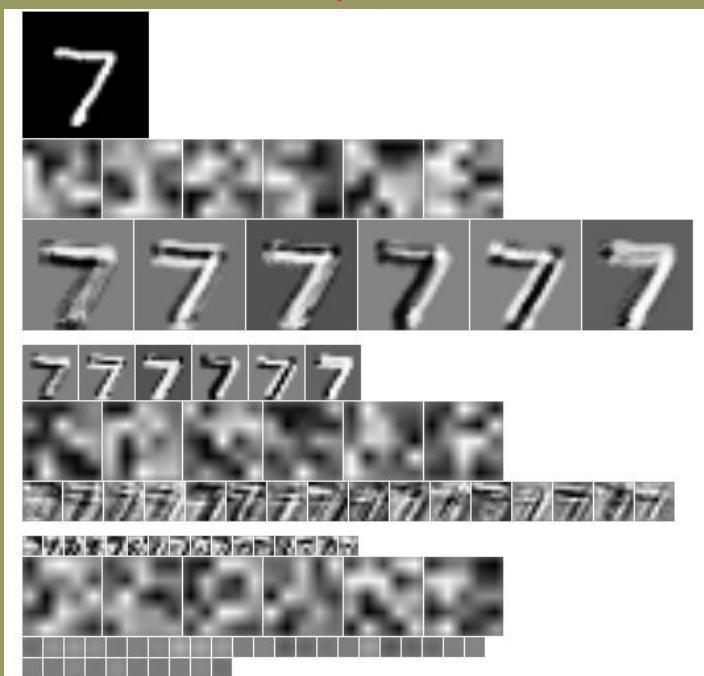


LENET X ESTADO DA ARTE (1998)



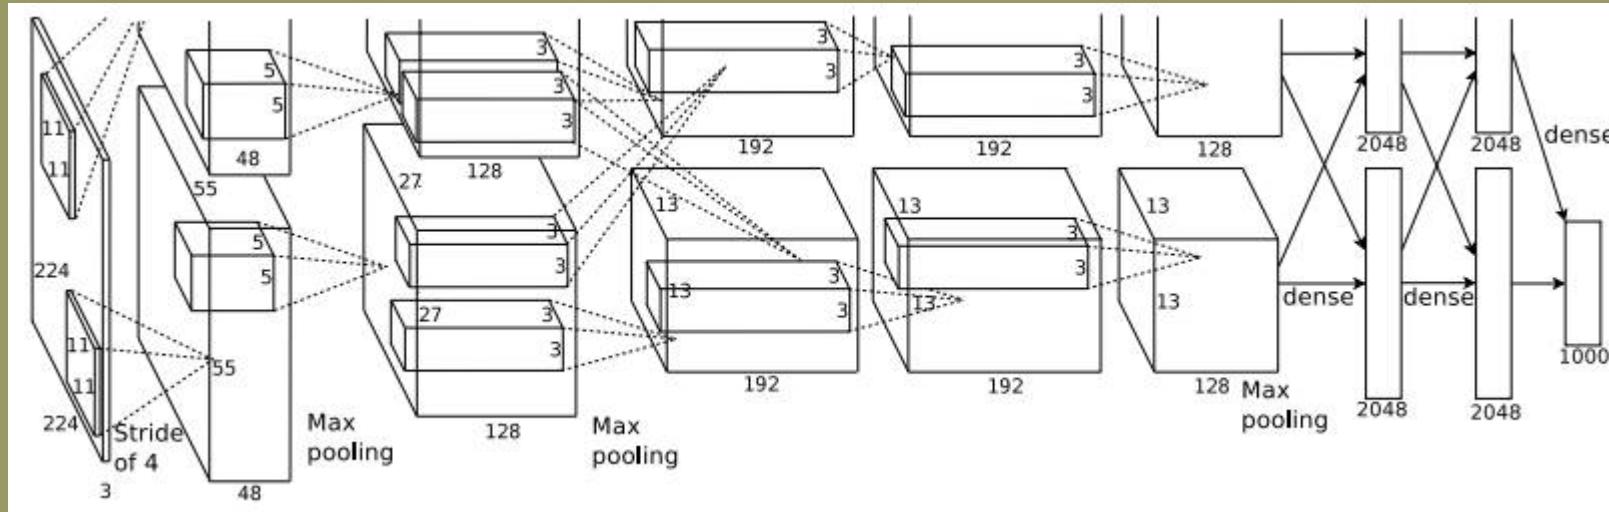
LENET

Filtros por Camada



Resistência a ruídos, inclinação e
formatação

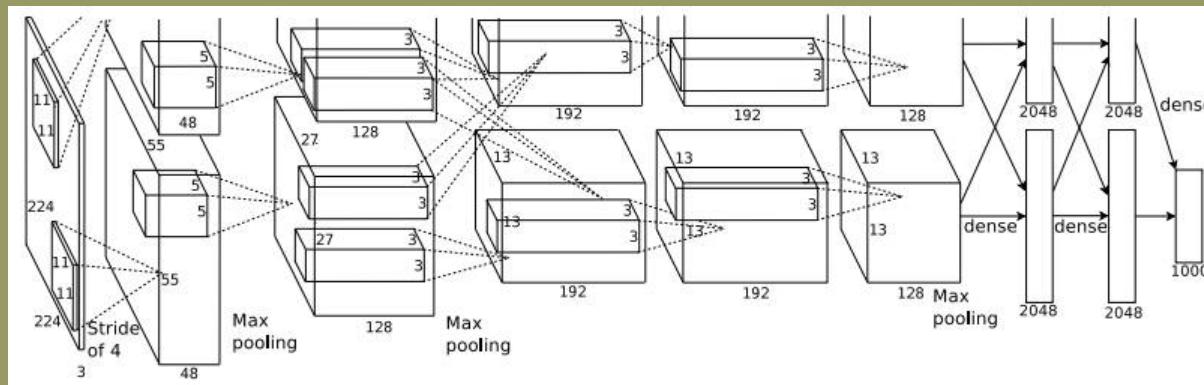
ALEXNET



- Alex Krizhevsky – 2012 (Krizhevsky Net)
- Imagenet 2012 Challenge (1000 classes)
 - 1.2 M Treinamento
 - 50 K Validação
 - 150 K Teste
- Vencedor (erro 15.3% - Top 5)
 - 2º SIFT Based (26.2%)



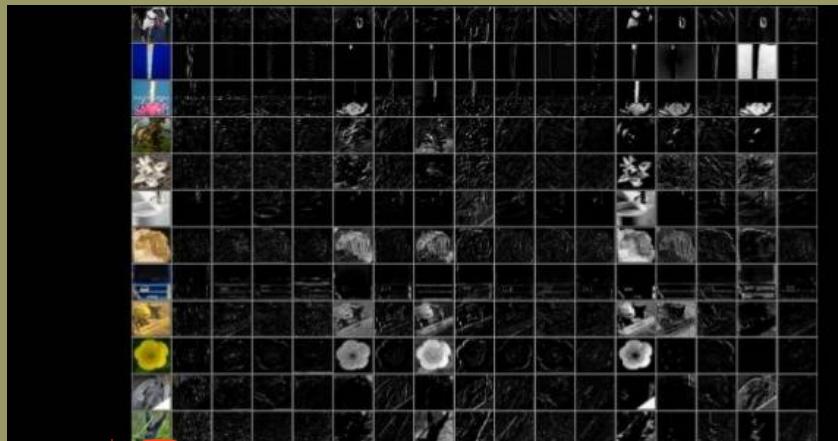
ALEXNET



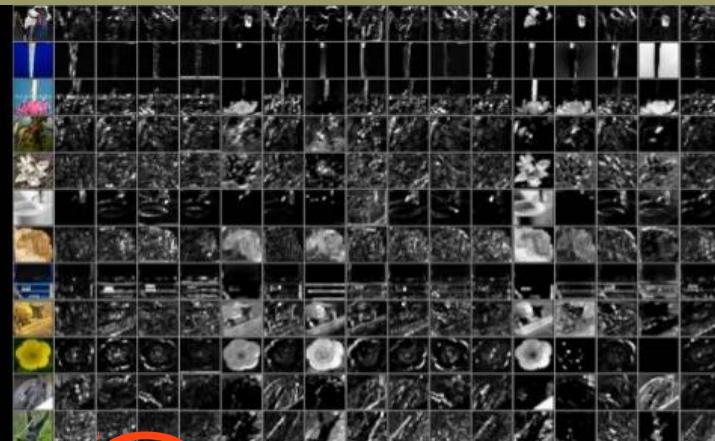
- Neurônios por Camada: ~253k, ~186k, ~64k , ~64k, ~43k, ~4k, ~4k, ~1k
- 60 M de Parâmetros
- Treinamento
 - 6 dias
 - 02 PLACAS GPU's (NVIDIA GTX 580 3GB)

- <http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>

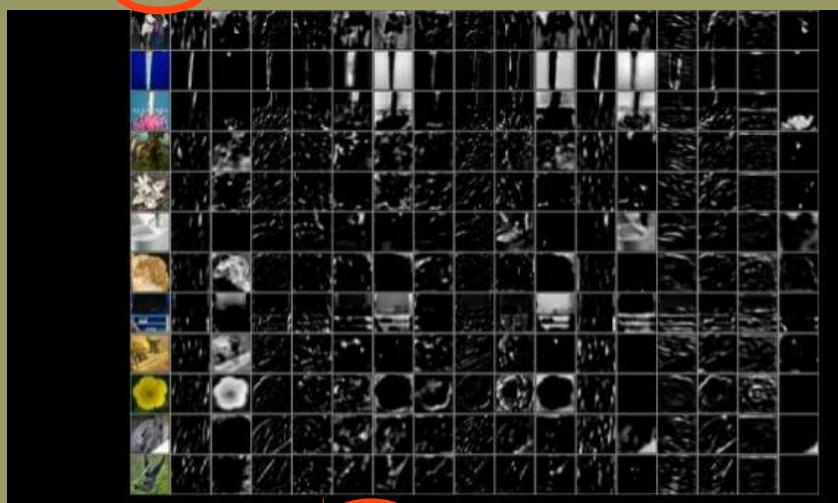
ALEXNET



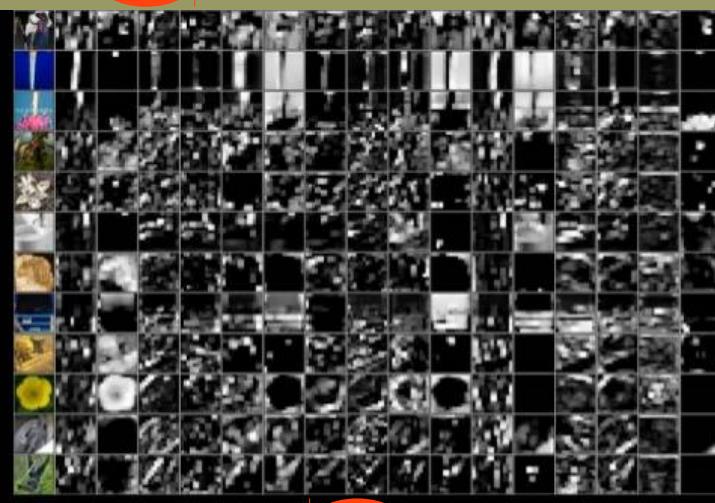
data -> conv1 -> pool1 -> conv2 -> pool2 -> conv3 -> conv4 -> conv5 -> pool3



data -> conv1 -> pool1 -> conv2 -> pool2 -> conv3 -> conv4 -> conv5 -> pool3

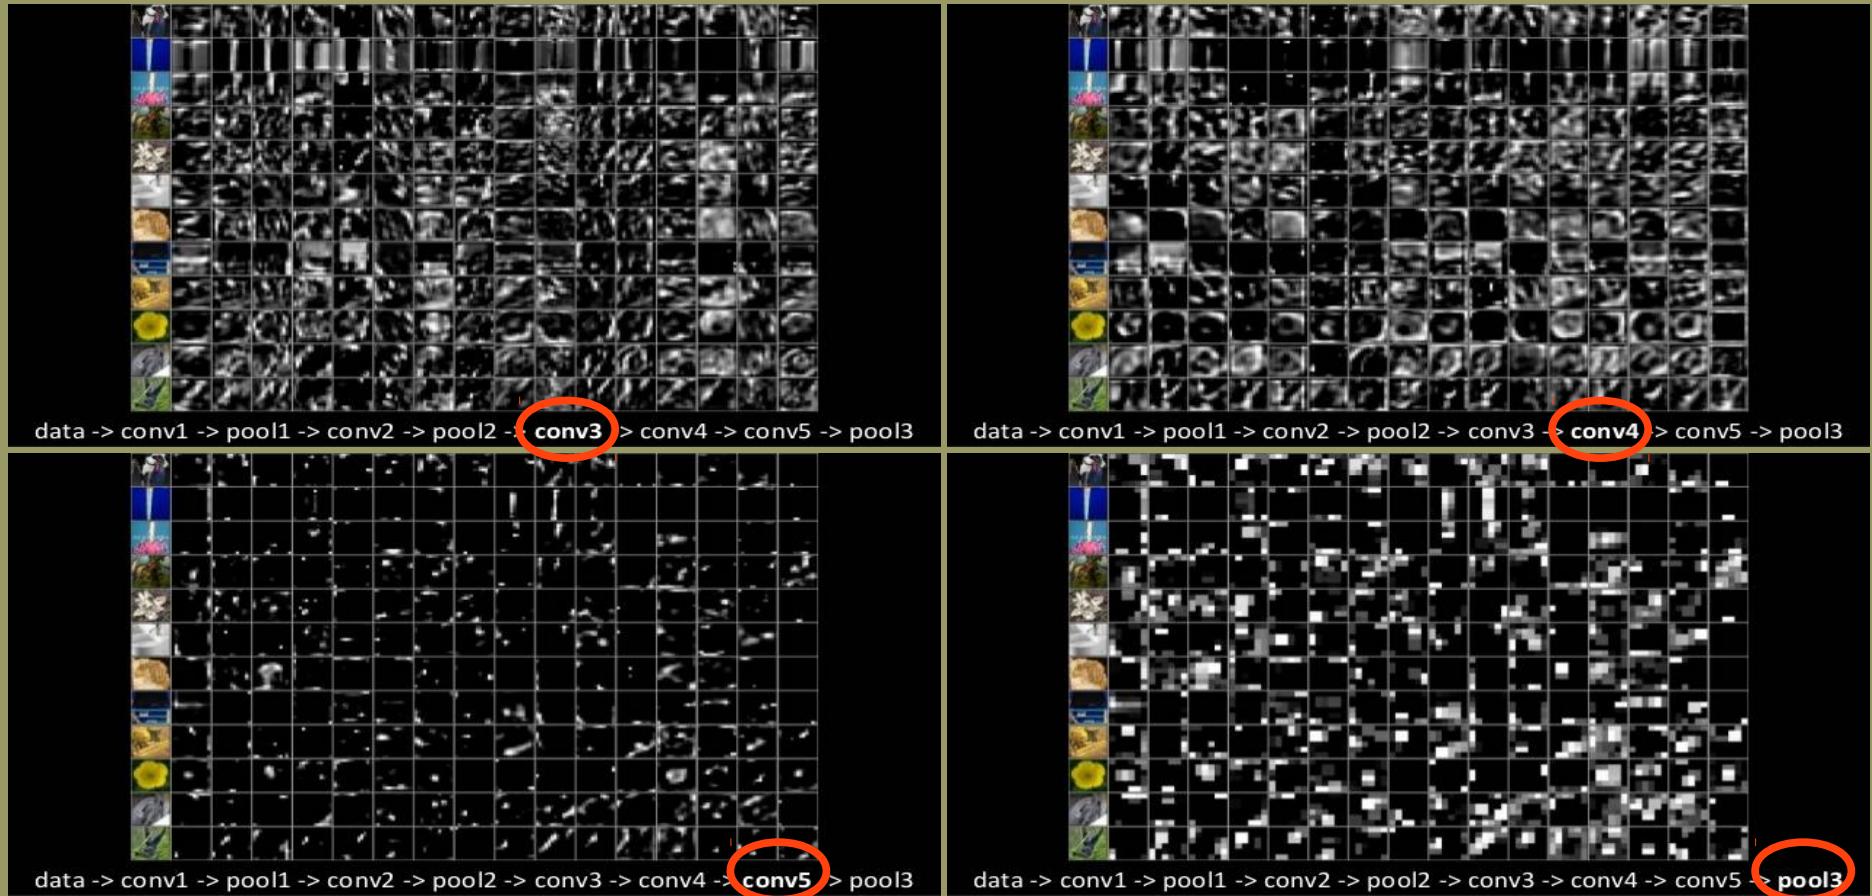


data -> conv1 -> pool1 -> conv2 -> pool2 -> conv3 -> conv4 -> conv5 -> pool3

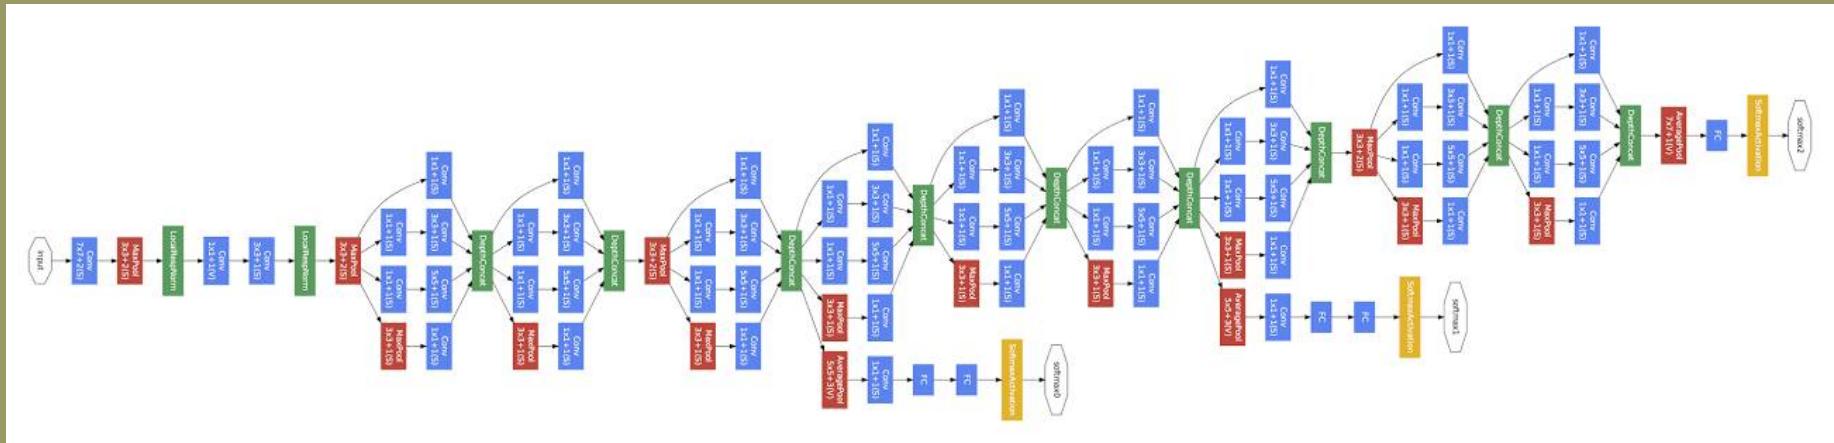


data -> conv1 -> pool1 -> conv2 -> pool2 -> conv3 -> conv4 -> conv5 -> pool3

ALEXNET



GOOGLE NET



- Imagenet 2014 Challenge (1000 classes)
 - 1.2 M Treinamento
 - 50 K Validação
 - 100 K Teste
- Vencedor (erro 6.67% - Top 5)
 - 2º CNN Based (7.32%) e 3º CNN Based (7.35%)

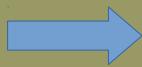
<http://www.cs.unc.edu/~wliu/papers/GoogLeNet.pdf>

GOOGLE NET

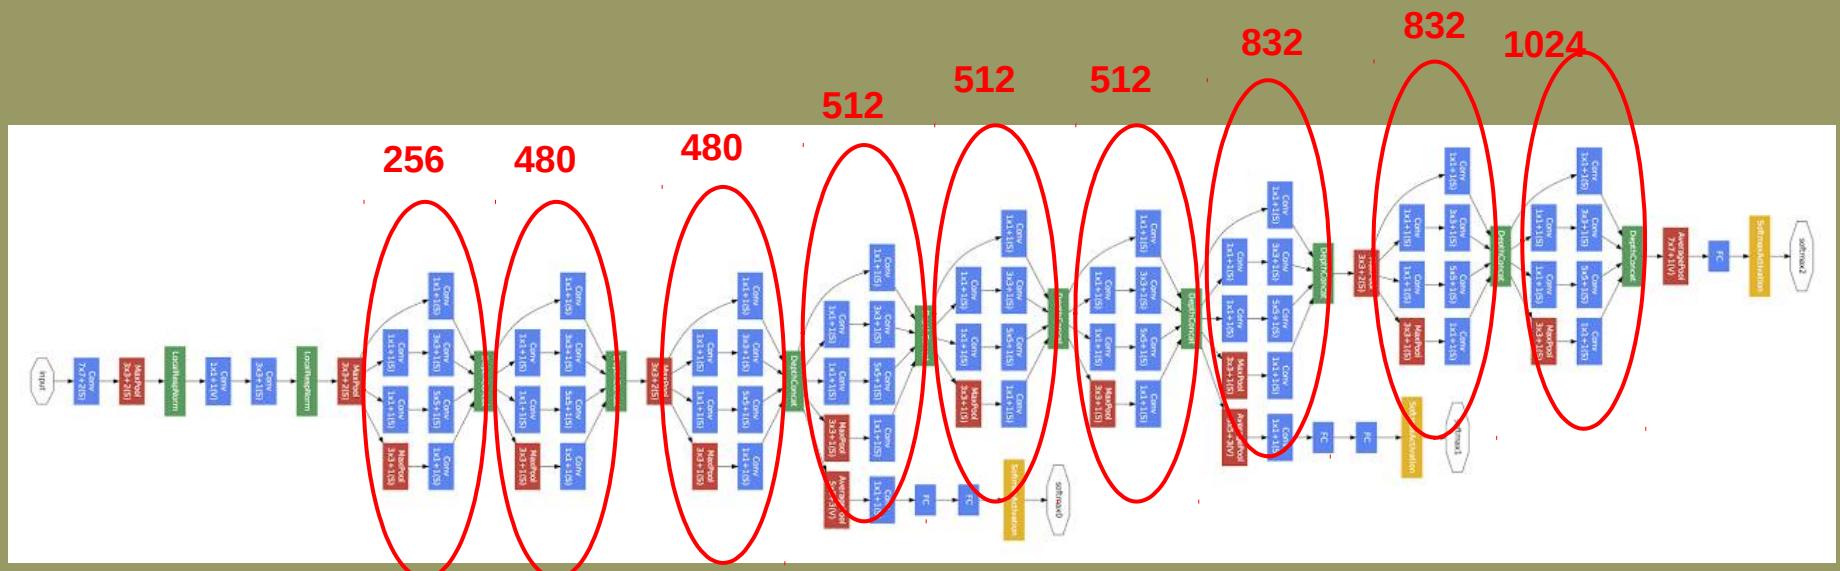
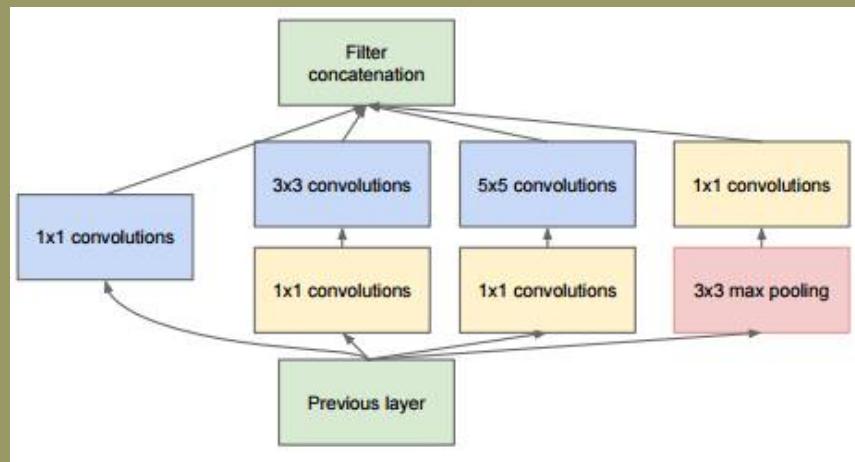
- Inceptions: 256 filtros até 1024 filtros

- Redes dentro de Redes !

Inceptions



- Custo computacional “apenas” 2x mais que AlexNet

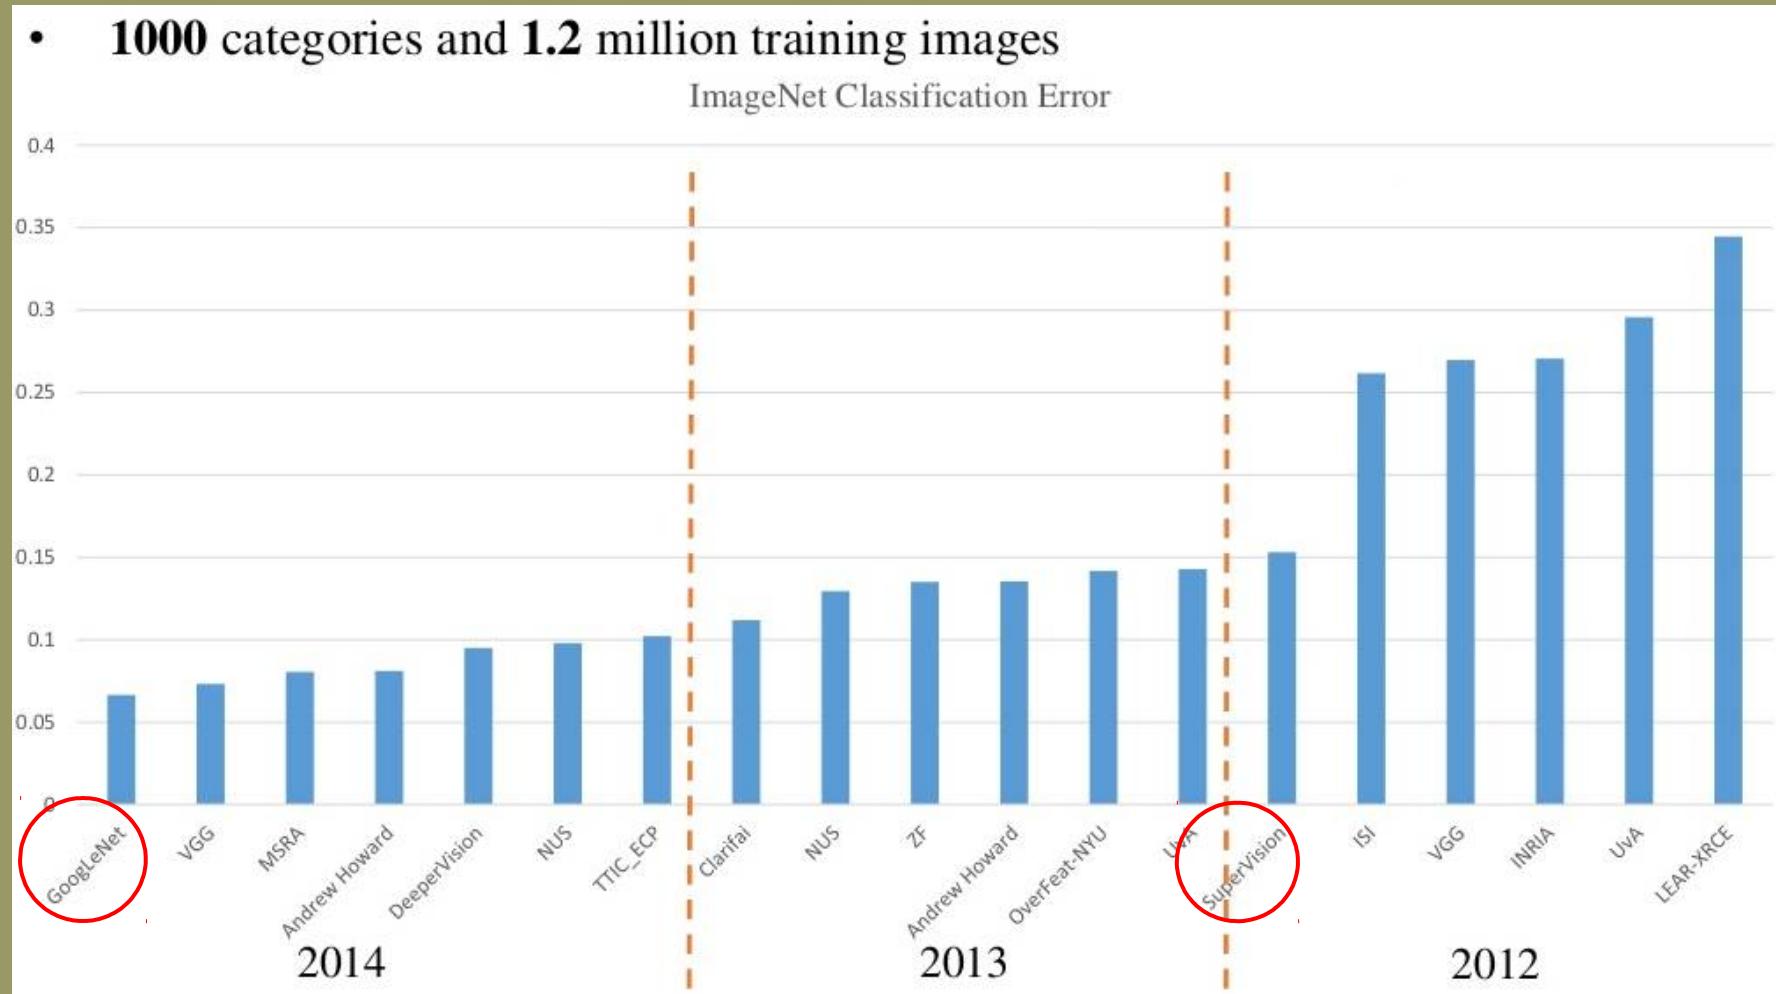


GOOGLE NET

type	patch size/ stride	output size	depth	#1×1	#3×3 reduce	#3×3	#5×5 reduce	#5×5	pool proj	params	ops
convolution	7×7/2	112×112×64	1							2.7K	34M
max pool	3×3/2	56×56×64	0								
convolution	3×3/1	56×56×192	2		64	192				112K	360M
max pool	3×3/2	28×28×192	0								
inception (3a)		28×28×256	2	64	96	128	16	32	32	159K	128M
inception (3b)		28×28×480	2	128	128	192	32	96	64	380K	304M
max pool	3×3/2	14×14×480	0								
inception (4a)		14×14×512	2	192	96	208	16	48	64	364K	73M
inception (4b)		14×14×512	2	160	112	224	24	64	64	437K	88M
inception (4c)		14×14×512	2	128	128	256	24	64	64	463K	100M
inception (4d)		14×14×528	2	112	144	288	32	64	64	580K	119M
inception (4e)		14×14×832	2	256	160	320	32	128	128	840K	170M
max pool	3×3/2	7×7×832	0								
inception (5a)		7×7×832	2	256	160	320	32	128	128	1072K	54M
inception (5b)		7×7×1024	2	384	192	384	48	128	128	1388K	71M
avg pool	7×7/1	1×1×1024	0								
dropout (40%)		1×1×1024	0								
linear		1×1×1000	1							1000K	1M
softmax		1×1×1000	0								

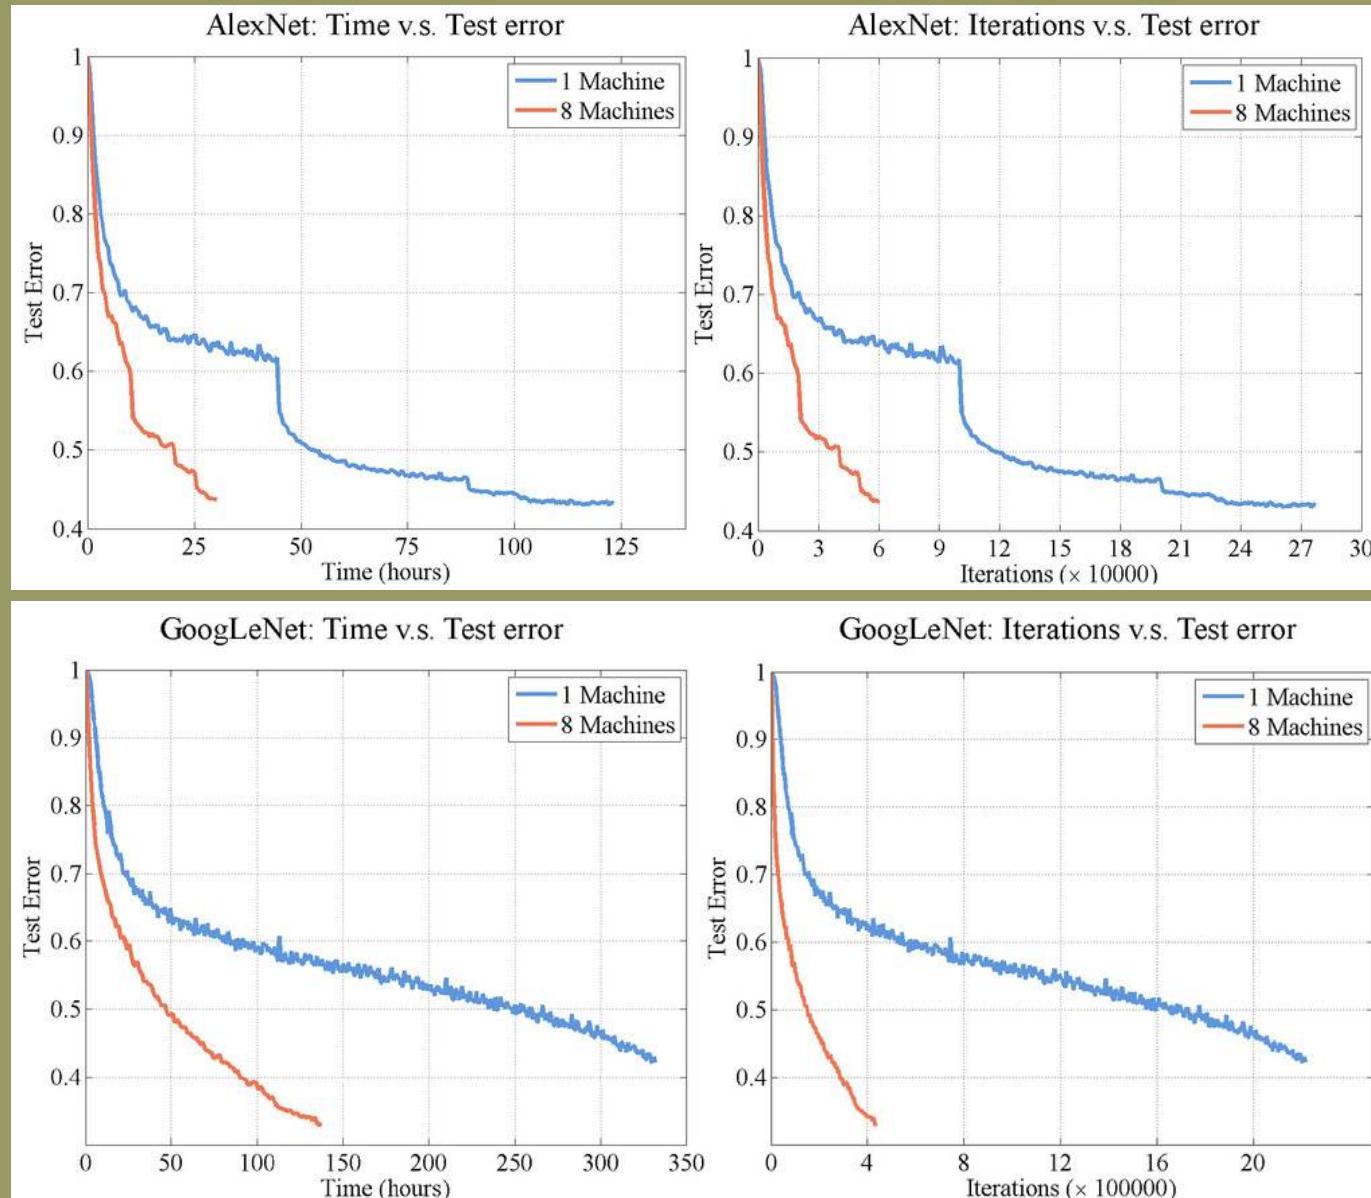
Imagenet Challenge

- Evolução (redução de erro) em casos complexos em apenas 2 anos !!
- **1000 categories and 1.2 million training images**



Imagenet Challenge

- AlexNet x GoogleNet (Poseidon FrameWork)



GOOGLE NET “DREAMS”

Imagen
Entrada



GOOGLE NET “DREAMS”

Porque aparecem cães nas imagens ?



Em 2012, o google utilizou uma parte da Imagenet, para treinar sua rede. Esse “subset” era composto por imagens de cães apenas. Então a rede aprendeu a extrair características com base em cães !

TRANSFER LEARNING !!

FrameWork CAFFE DEEP LEARNING

- Implementação C++ / CUDA (GPU)
- Python Interface
- SITE: <http://caffe.berkeleyvision.org/>
- Tutorial de Instalação:

<http://www.inf.ufpr.br/aghochuli/caffe/>

<http://caffe.berkeleyvision.org/installation.html>

- Tutorial Configuração da CNN (layers):
<http://caffe.berkeleyvision.org/tutorial/>

FrameWork CAFFE DEEP LEARNING

- lenet_solver.prototxt

```
# The train/test net protocol buffer definition.
net: "dummy/models/lenet/lenet_train_val.prototxt"
# test_iter specifies how many forward passes the test should carry out.
# In the case of MNIST, we have test batch size 100 and 100 test iterations,
# covering the full 10,000 testing images.
test_iter: 100
# Carry out testing every 500 training iterations.
test_interval: 500
# The base learning rate, momentum and the weight decay of the network.
base_lr: 0.01 ←
momentum: 0.9 ←
weight_decay: 0.0005
# The learning rate policy.
lr_policy: "inv"
gamma: 0.0001
power: 0.75
# Display every 100 iterations.
display: 100
# The maximum number of iterations.
max_iter: 10000
# snapshot intermediate results.
snapshot: 2000
snapshot_prefix: "dummy/models/lenet/lenet"
# solver mode: CPU or GPU.
solver_mode: GPU
```

FrameWork CAFFE DEEP LEARNING

- lenet_train_val.prototxt : Data Sources

```
name: "LeNet"
layer {
    name: "script"
    type: "Data"
    top: "data"
    top: "label"
    include {
        phase: TRAIN
    }
    transform_param {
        scale: 0.00390625 ← 1 / 256
    }
    data_param {
        source: "dummy/data/dummy_train_lmdb"
        batch_size: 64
        backend: LMDB
    }
}

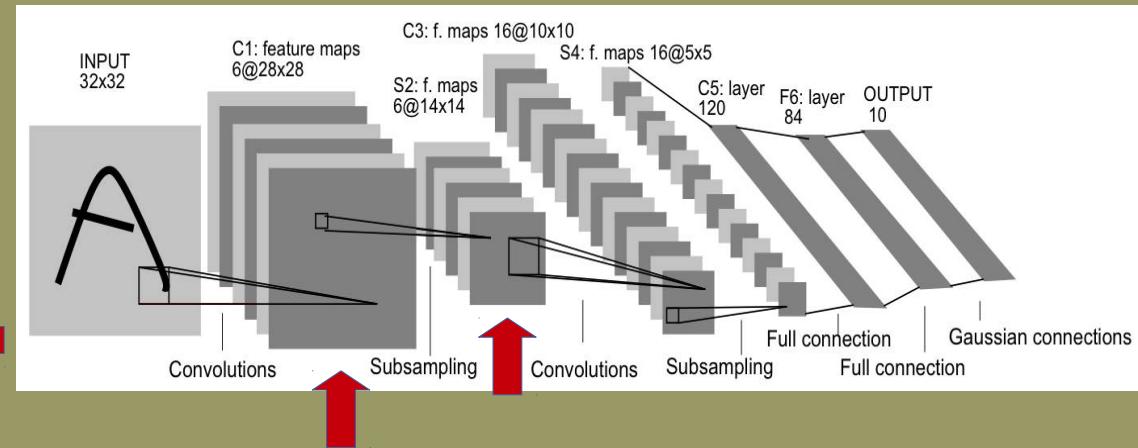
layer {
    name: "mnist"
    type: "Data"
    top: "data"
    top: "label"
    include {
        phase: TEST
    }
    transform_param {
        scale: 0.00390625 ← 1 / 256
    }
    data_param {
        source: "dummy/data/dummy_val_lmdb"
        batch_size: 64
        backend: LMDB
    }
}
```

FrameWork CAFFE DEEP LEARNING

- lenet_train_val.prototxt : Layers

```
layer {  
    name: "conv1"  
    type: "Convolution"  
    bottom: "data"  
    top: "conv1"  
    param {  
        lr_mult: 1  
    }  
    param {  
        lr_mult: 2  
    }  
    convolution_param {  
        num_output: 6 ←  
        kernel_size: 5  
        stride: 1  
        weight_filler {  
            type: "xavier"  
        }  
        bias_filler {  
            type: "constant"  
        }  
    }  
}
```

```
layer {  
    name: "pool1"  
    type: "Pooling"  
    bottom: "conv1"  
    top: "pool1"  
    pooling_param {  
        pool: MAX  
        kernel_size: 2  
        stride: 2  
    }  
}
```

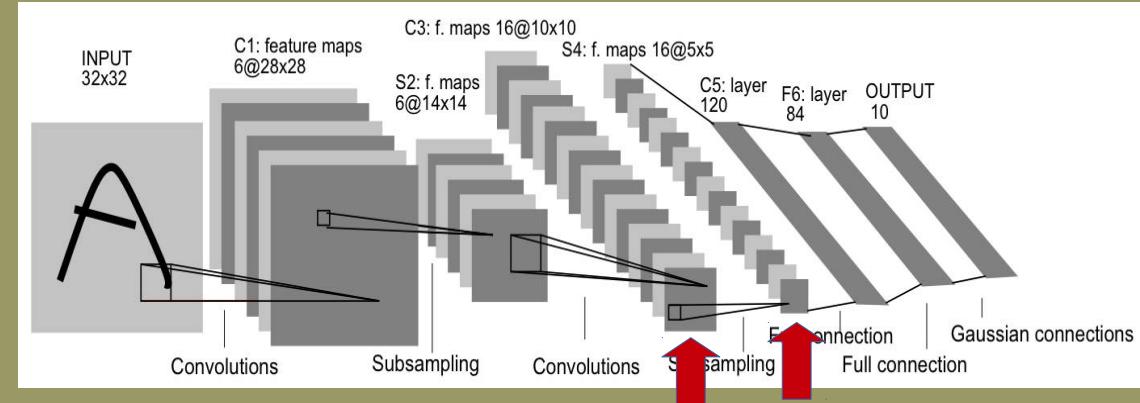


FrameWork CAFFE DEEP LEARNING

- lenet_train_val.prototxt : Layers

```
layer {  
    name: "conv2"  
    type: "Convolution"  
    bottom: "pool1"  
    top: "conv2"  
    param {  
        lr_mult: 1  
    }  
    param {  
        lr_mult: 2  
    }  
    convolution_param {  
        num_output: 16  
        kernel_size: 5  
        stride: 1  
        weight_filler {  
            type: "xavier"  
        }  
        bias_filler {  
            type: "constant"  
        }  
    }  
}
```

```
layer {  
    name: "pool2"  
    type: "Pooling"  
    bottom: "conv2"  
    top: "pool2"  
    pooling_param {  
        pool: MAX  
        kernel_size: 2  
        stride: 2  
    }  
}
```



FrameWork CAFFE DEEP LEARNING

- lenet_train_val.prototxt : Layers

```
layer {  
    name: "conv3"  
    type: "Convolution"  
    bottom: "pool2"  
    top: "conv3"  
    param {  
        lr_mult: 1  
    }  
    param {  
        lr_mult: 2  
    }  
    convolution_param {  
        num_output: 120  
        kernel_size: 1  
        stride: 1  
        weight_filler {  
            type: "xavier"  
        }  
        bias_filler {  
            type: "constant"  
        }  
    }  
}
```

```
layer {  
    name: "ip1"  
    type: "InnerProduct"  
    bottom: "conv3"  
    top: "ip1"  
    param {  
        lr_mult: 1  
    }  
    param {  
        lr_mult: 2  
    }  
    inner_product_param {  
        num_output: 84  
        weight_filler {  
            type: "xavier"  
        }  
        bias_filler {  
            type: "constant"  
        }  
    }  
    layer {  
        name: "relu1"  
        type: "ReLU"  
        bottom: "ip1"  
        top: "ip1"  
    }  
}
```

```
layer {  
    name: "ip2"  
    type: "InnerProduct"  
    bottom: "ip1"  
    top: "ip2"  
    param {  
        lr_mult: 1  
    }  
    param {  
        lr_mult: 2  
    }  
    inner_product_param {  
        num_output: 10  
        weight_filler {  
            type: "xavier"  
        }  
        bias_filler {  
            type: "constant"  
        }  
    }  
    layer {  
        name: "prob"  
        type: "Softmax"  
        bottom: "ip2"  
        top: "prob"  
    }  
}
```

